



IRIDE




CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

**Innovative Radiation Dose Estimation for Pediatric
Retinoblastoma Treatment Enhancement**



INTRODUZIONE AL PROGETTO IRIDE

Innovative Radiation Dose Estimation for Pediatric Retinoblastoma Treatment Enhancement



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

CONTESTO CLINICO E MOTIVAZIONE

- **Retinoblastoma:** tumore maligno della retina in età pediatrica.
- In casi selezionati, la brachiterapia con **placca di Rutenio-106** è un'opzione conservativa.
- Obiettivo clinico: **trattare il tumore preservando i tessuti sani.**


LIMITE DELL'APPROCCIO ATTUALE

- La pianificazione richiede simulazioni Monte Carlo accurate in Geant4.
- La ricerca della configurazione ottimale della placca è computazionalmente costosa.
- Questo limita un'ottimizzazione rapida del trattamento.

OBIETTIVO DEL PROGETTO IRIDE

- Sviluppare un **modello surrogato differenziabile** delle simulazioni Monte Carlo.
- Stimare rapidamente dose e tempo di trattamento dalla geometria della placca.
- Supportare l'ottimizzazione del posizionamento nel rispetto dei **vincoli clinici.**

APPROCCIO ODIERNO VS APPROCCIO OBIETTIVO FUTURO




La placca viene mantenuta a contatto con l'occhio fino alla somministrazione della dose prescritta all'apice del tumore. Il tempo di impianto è calcolato a partire dall'attività misurata lungo l'asse della placca a diverse profondità.

Caratterizzare in 3D ciascuna placca per ricostruirne l'attività nell'intero volume. Utilizzare queste informazioni in Geant4 per sviluppare un piano di trattamento che consideri la distribuzione di dose nell'intero tumore e nei tessuti sani.

Task 0: Creazione del Dataset

Costruzione della regione apicale





CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

- 1 SELEZIONE DELLA REGIONE APICALE (ROI):**
Individuazione dell'apice tumorale a profondità clinica (6.0 mm) e definizione di una ROI sferica ($R=3.5$ mm) su cui mediare la dose.

- 2 TENSORE GEOMETRICO DI INPUT (5 feature):**
Per ogni angolo di simulazione ($\theta \in [0, 355]$ a passi di 5), le coordinate angolari vengono parametrizzate con funzioni trigonometriche $[\sin\theta, \cos\theta, \sin\phi, \cos\phi]$ e unite al raggio radiale totale r per evitare discontinuità.


- 3 CALCOLO DEL TEMPO DI TRATTAMENTO:**
Determinazione del rateo di dose medio sulla ROI apicale (su 10 run Monte Carlo) per ricavare il tempo esatto necessario a somministrare la dose target prescritta di 50 Gy.

- 4 TENSORE DOSIMETRICO DI OUTPUT (19 feature):**
Integrazione della dose accumulata durante il trattamento su 6 strutture anatomiche (Cristallino, Retina, Cornea, Nervo Ottico, Sclera, Tumore), estraendo per ciascuna la tripla statica: Dose Media (D_{media}), Deviazione Standard (σ) e Dose Massima (D_{max}).




TASK 1

Costruzione del Modello Surrogato



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE




MAPPATURA DEL MODELLO

- Il modello apprende la relazione tra la geometria della placca e la corrispondente risposta dosimetrica.

$$\mathbf{x}_i \in \mathbb{R}^5 \xrightarrow{f_{\text{NN}}} \hat{\mathbf{y}}_i \in \mathbb{R}^{19}$$

- INPUT** : 5 Feature geometriche
- OUTPUT**: Tempo di trattamento + 3 metriche di dose per 6 strutture oculari



INPUT

- 72 configurazioni** della placca
- Campionamento con passo angolare di 5°

$$[\sin \theta, \cos \theta, \sin \phi, \cos \phi, r_{\text{totale}}]$$

- Le trasformazioni trigonometriche garantiscono una **rappresentazione continua degli angoli**.



PROCESSING

- Suddivisione dei dati in **training, validation e test set**.
- Trasformazione** dei target:

$$y' = \ln(1 + y)$$

- Standardizzazione** di input e output utilizzando il training set, evitando il data leakage.



DATA AUGMENTATION


- Applicata esclusivamente al training set.

$$\theta_{\text{aug}} = \theta + \varepsilon_\theta,$$

$$\varepsilon_\theta \sim \mathcal{N}(0, 1^\circ{}^2)$$

$$\sigma_\theta = 1^\circ$$


- Ogni campione viene affiancato da **configurazioni perturbate**.



NEURAL NETWORK

- Modello neurale completamente differenziabile:

- Layer fully connected;
- Attivazione **GELU**;
- Dropout** p=0.15;
- Strato finale con **19 output**.




ADDESTRAMENTO

Ottimizzazione mediante:

- Weighted MSE Loss**
- Adam con weight decay;
- Scheduler **ReduceLROnPlateau**
- Massimo **500 epoche**
- Selezione sulla validation loss.

TRE STRATEGIE DI SPLITTING — **RANDOM, SISTEMATICO E CONTINUO ANGOLARE** — PER VALUTARE INTERPOLAZIONE, STABILITÀ ED ESTRAPOLAZIONE DEL MODELLO.

TASK 2: Pianificazione inversa e Ottimizzazione geometrica



OBIETTIVI PRINCIPALI

- **Ottimizzazione del posizionamento della placca:** Estrapolazione della miglior configurazione angolare
- **Ricerca differenziabile:** La miglior configurazione possibile può essere definita in modo continuo



Campionamento discreto (Grid Search)

- **Spazio fisico:** $\theta \in [0^\circ; 360^\circ)$, $\Delta\theta = 5^\circ$
- **72 Configurazioni angolari**
- **Filtraggio booleano**




Gradient Descent

- **Ottimizzazione continua**
- **Vincoli convertiti in penalità**
- **Approccio multi-start**


PRINCIPALI DIFFICOLTÀ

- **Limiti di dose:** La miglior configurazione è la configurazione che rispetta tutti i vincoli di dose della prescrizione.




INPUT

L'input dell'algoritmo è formato dalle 5 feature geometriche



PROCESSING

Standardizzazione dell'input e predizione del modello



FILTRAGGIO


Estrazione delle metriche e scoring dei risultati



RISULTATO

Estrazione delle configurazioni migliori

TASK 3: Valutazione della robustezza della configurazione ottimale



OBIETTIVI PRINCIPALI


- **Ricerca iterativa con Monte Carlo Dropout:**
Viene ripetuta la ricerca della configurazione ottimale N volte per giudicare il livello di confidenza del risultato
- **Distribuzione di probabilità delle configurazioni:** Iterazione della tecnica di Gradient Descent per costruire una distribuzione statistica continua

- Dropout acceso
- Simulazioni MC ed estrazione variabili dosimetriche
- Costruzione dello score in termini di probabilità di estrazione




MODELLO 1: SPLIT RANDOM

Multi-Layer Perceptron con splitting random



DEFINIZIONE DELLO SPLIT


- **Split angolare random del dataset:**
- **Divisione del dataset in modo randomico**
- **80% train, 10% test e 10% validation**



Sottoinsieme	Numero di elementi
Training	57
Validation	7
Test	8

SCELTE NELL'ARCHITETTURA

- **Struttura a Layer:** Architettura feed-forward sequenziale progettata per la compressione e trasformazione progressiva dallo spazio di input a quello di output (5→64→32→19 neuroni).
- **Attivazioni GELU:** Utilizzo della funzione Gaussian Error Linear Unit dopo ciascun layer nascosto per garantire una trasformazione liscia e completamente differenziabile, essenziale per la successiva fase di ottimizzazione.
- **Regolarizzazione via Dropout (p=0.15):** Applicato dopo ogni attivazione per ridurre il rischio di overfitting e prevenire l'adattamento mnemonico, data la dimensione contenuta del dataset originale.
- **Output Layer:** Layer finale lineare a 19 unità per la ricostruzione simultanea di tutte le metriche dosimetriche e del tempo di trattamento.



MODELLO 1: SPLIT RANDOM

Loss Pesata e Strategia di Training

Inizializzazione & Custom Loss Pesata

Abbiamo implementato una CustomWeightedMSELoss che applica un vettore di pesi (w) per penalizzare gli errori in base al tempo di trattamento e alla rilevanza clinica delle strutture anatomiche:

$$L_{custom} = \frac{1}{N} \sum_i \omega_i (y_i - \hat{y}_i)^2$$

Struttura / Variabile	Pesi Assegnati (w_i)
Tempo di trattamento	50.0
Cristallino	[10.0, 2.5, 15.0]
Retina	[10.0, 2.5, 10.0]
Cornea	[10.0, 1.5, 15.0]
Nervo Ottico	[15.0, 1.5, 20.0]
Sclera	[10.0, 1.5, 15.0]
Tumore	[20.0, 1.5, 15.0]




Processo di Training & Ottimizzazione

- Ottimizzazione Adaptiva & Regolarizzazione:** Aggiornamento dei pesi tramite Adam con penalizzazione L2(weight_decay) per evitare l'overfitting sui dati aumentati.
- Gestione del Learning Rate:** Dinamica guidata da ReduceLROnPlateau: riduce il passo del 20% ad ogni stallo della Validation Loss (patience: 50 epoche).
- Checkpointing & MC Dropout:** Salvataggio dello stato con miglior Validation Loss. Inferenza su 100 simulazioni Monte Carlo (con Dropout attivo) per valutare media ed incertezza (σ) delle predizioni.


Iperparametro	Configurazione
Ottimizzatore	Adam
Learning rate iniziale	$\eta_0 = 0.001$
Weight decay (L ₂)	$\lambda = 10^{-4}$
Scheduler	ReduceLROnPlateau
Patience dello scheduler	50 epoche
Fattore di riduzione LR	0.8
Numero massimo di epoche	500
Simulazioni MC Dropout	100
Funzione di loss	Custom Weighted MSE

MODELLO 1: SPLIT RANDOM


Curve di Apprendimento




LEARNING CURVES: ASPETTI GENERALI




CONVERGENZA Rapida: 20-30 epoche



NO OVERFITTING: Validation Loss e Training Loss parallele e allineate lungo tutto il training



GENERALIZZAZIONE: Garantita da Dropout ($p=0.15$) e Data Augmentation Fisica ($\times 30$)





SCHEDULING & PLATEAU: ReduceLROnPlateau riduce il passo nei plateau



CHECKPOINT MIGLIOR MODELLO:
Epoca Ottimale $\rightarrow$ 417
Min Val Loss $\rightarrow$ 0.0399


MODELLO 1: SPLIT RANDOM

Predizione sul tempo



RILEVANZA CLINICA & PESO DEDICATO

Il tempo di trattamento rappresenta il parametro chiave vincolato dal peso maggioritario ($w=50.0$) nella Loss Custom. Il modello risponde con un allineamento pressoché perfetto lungo la bisettrice ($y=x$).



INCERTEZZA TEMPORALE (MC DROPOUT)

Le barre d'errore (100 simulazioni Monte Carlo) mostrano una deviazione standard contenuta, confermando l'elevata stabilità e affidabilità della predizione sul parametro temporale.




ACCURATEZZA SU DIVERSE SCALE


Ottima capacità di interpolazione sia sui tempidi trattamento brevi (fasi iniziali/frazioni ridotte) sia su durate estese (~1500 giorni), senza derive o sottostime sistematiche.

MODELLO 1: SPLIT RANDOM

Predizione sulla Dose Media




Performance del Modello Surrogato: DOSE MEDIA (Gy)



ACCURATEZZA E LINEARITÀ

Le predizioni si allineano lungo la bisettrice ($y=x$) per tutte le 6 strutture anatomiche, confermando la capacità della rete di modellare accuratamente la dose su diversi ordini di grandezza.



STIMA DELL'INCERTEZZA

Le barre d'errore verticali derivano dalle 100 simulazioni di Monte Carlo Dropout. Mostrano un'incertezza contenuta e coerente, fornendo una stima probabilistica affidabile per ogni predizione.




STABILITÀ E ROBUSTEZZA


Assenza di fenomeni di saturazione sia per gli Organi a Rischio (OAR) che per il Tumore, garantendo elevata precisione sia alle basse che alle altissime dosi

MODELLO 1: SPLIT RANDOM

Predizione sulla Dose Massima




Performance del Modello Surrogato: DOSE MASSIMA (Gy)





MODELLO 1: SPLIT RANDOM

Metriche d'errore: MAE e MAPE



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE



L'analisi congiunta delle metriche MAE e MAPE costituisce la validazione quantitativa del modello surrogato. In particolare, il grafico del MAPE dimostra che gli elevati valori di MAE riscontrati sulle dosi massime sono legati unicamente alla scala fisica della grandezza: l'errore percentuale relativo si mantiene sempre ridotto, garantendo stime stabili ed accurate per ciascun target clinico.

MODELLO 1: SPLIT RANDOM



Task 2: Ottimizzazione della Posizione Chirurgica

Task 2a: Ricerca Discreta

Esplorazione su Griglia Discreta ($\Delta\theta=5^\circ$):

- Analisi Vincoli Clinici:** Su 72 nodi angolari analizzati, 9 configurazioni rispettano tutti i limiti di radioprotezione definiti per gli OAR.
- Configurazione Ottimale ($\theta=0^\circ$):**
Tempo predito = 6.46 giorni
Score Max OAR (tot) = 10.93

Organo	Dose Predetta (Gy)	Soglia Clinica (Gy)
Cristallino	0.48	5.0
Retina	28.54	45.0
Cornea	2.12	50.0
Nervo Ottico	7.32	55.0
Sclera	47.49	100.0



Task 2b: Ottimizzazione Continua Differenziabile

Raffinamento Continuo Gradient-Based (Multi-Start):

- Esplorazione Spazio delle Soluzioni:**
L'ottimizzazione parte da 4 angoli indipendenti ($0^\circ, 90^\circ, 180^\circ, 270^\circ$).
- Penalizzazione Vincoli:** I percorsi da $90^\circ, 180^\circ, 270^\circ$ cadono in regioni ad altissima penalità ($L_{tot} > 10^7$).

Start Angle (θ_0)	Angolo Finale (θ^*)	L_{tot}	Esito / Note
0°	$359.79^\circ (-0.21^\circ)$	10.9304	Minimo Globale
90°	55.22°	4.92×10^7	Violazione vincoli
180°	180.44°	6.70×10^{10}	Violazione vincoli
270°	309.53°	4.73×10^7	Violazione vincoli


MODELLO 1: SPLIT RANDOM

Analisi di Robustezza e Incertezza Stocastica


Task 3a: Incertezza Continua (MC Dropout)

Metodo: Integrazione del campionamento Monte Carlo Dropout (N=1000) nel ciclo di ottimizzazione differenziabile.

Obiettivo: Determinare la distribuzione di probabilità empirica dell'angolo ottimale, $p(\theta)$, a fronte delle fluttuazioni stocastiche dei pesi della rete



Parametro	Valore
Media θ	0.76
Incertezza σ	±4.21
Intervallo al 95% CI	[−7.48, 9.00]



Task 3b: Robustezza Discreta (10.000 Iterazioni)


- Obiettivo:** Valutare la frequenza con cui ciascun angolo della griglia risulta il minimo assoluto a fronte di fluttuazioni nei dati e nei pesi della rete.
- Criterio di Vittoria:** Selezione della configurazione che minimizza la funzione obiettivo nel rispetto di tutti i vincoli clinici.

Angolo Discreto (θ)	Frequenza di Vittoria (%)	Iterazioni Stocastiche
0°	33.2%	3.322
5°	24.3%	2.434
355° (−5°)	22.6%	2.255
10°	9.2%	921
350° (−10°)	6.2%	623

- Dominanza del Settore Simmetrico:** L'angolo $\theta=0$ è la singola posizione più frequente (33.2%). Considerando l'intorno di tolleranza tra −5 e +5 (355,0,5), la confidenza cumulativa raggiunge l'80.1% (8011 iterazioni su 10000).
- Affidabilità Chirurgica:** Il posizionamento ad angolo nullo non è solo l'ottimo nominale deterministico, ma rappresenta la scelta terapeutica più robusta e sicura a fronte dell'incertezza stocastica del modello.


MODELLO 2: SPLIT DETERMINISTICO

Multi-Layer Perceptron con Skip Connection e splitting deterministico



DEFINIZIONE DELLO SPLIT

- **Split angolare deterministico del dataset:**
- Divisione **omogenea** con l'operatore **modulo**
- Ogni 8 dati di **Training** si prende un **Validation** e un **Test**
- L'omogeneità aiuta il modello ad ottenere performance migliori pur dovendo considerare il **bias sistematico** introdotto.



Sottoinsieme	Numero di elementi
Training	58
Validation	7
Test	7

IDEA METODOLOGICA

Lo scopo è facilitare il lavoro di predizione del modello.

L'interpolazione avviene dopo che il modello ha imparato a descrivere configurazioni vicine a quella che deve predire.

Ogni posizione angolare sull'occhio è ispezionata omogeneamente.

PRESENZA DI BIAS SISTEMATICO

Avendo definito in modo univoco lo splitting, ad ogni nuova esecuzione del codice i dataset di training, validation e test **non verranno modificati**. Inoltre, avendo separato i dati in maniera deterministica, introduciamo un **bias sistematico e voluto** nel modello. Questo aspetto è fondamentale e deve essere opportunamente considerato nello sviluppo della rete.

- Il **Training Set** forma finestre di allenamento continue.
- Il **Validation Set** misura l'interpolazione dopo aver imparato le configurazioni di Training.
- Il **test** quantifica la capacità di estrapolare verso il tumore.

IMPLEMENTAZIONE NEL CODICE

```
# Creiamo un vettore sequenziale di indici
indici = np.arange(n_simulazioni)

# Vogliamo dividere il dataset in train,
# validation e test. Per farlo si usano
# delle maschere booleane per stabilire
# le condizioni di campionamento e
# riempimento dell'input (x) e output (y).
# L'operatore modulo (%) crea blocchi
# ripetitivi di 10 elementi da cui si estrapolano
# i dati.

# Maschere booleane basate sull'operatore modulo 10
mask_train = (indici % 10) < 8 # Indici: 0-7
mask_val   = (indici % 10) == 8 # Indici: 8
mask_test  = (indici % 10) == 9 # Indici: 9


# Estrazione deterministica dei dati di train,
# validation e test
X_train, y_train = X[mask_train], y[mask_train]
X_val, y_val     = X[mask_val], y[mask_val]
X_test, y_test  = X[mask_test], y[mask_test]

#=====

# Dataset caricato con successo!
# Simulazioni totali: 72
# Dati training: 58
# Dati validation: 7
# Dati test: 7
```


MODELLO 2: SPLIT DETERMINISTICO

Architettura della rete



SCELTE NELL'ARCHITETTURA


- MLP con Skip Connection per permettere all'algoritmo di ottimizzare il calcolo dei pesi solo sulle correzioni non lineari, preservando l'input.
- La rete presenta 4 layer
- All'uscita di ciascun layer lineare è posto un layer di attivazione GELU che garantisce continuità e differenziabilità, utili nell'ottimizzazione.
- Dropout $p=0.15$ come tecnica di regolarizzazione posto prima dell'ultimo layer; il dropout riduce il rischio di overfitting dovuto alla dimensione limitata del dataset.
- Prima del Dropout layer avviene la somma tra l'output elaborato dalla rete e l'originale.

MOTIVAZIONE DELLA SCELTA

Grazie alla Skip Connection si ottiene:

- **Facilità nel flusso dei gradienti**
- **Focalizzazione sulle correzioni non lineari**
- **Maggiore rapidità di convergenza e stabilità**

ARCHITETTURA DELLA RETE




IMPLEMENTAZIONE NEL CODICE

```
class ModelloSurrogato(nn.Module):  
  
    def __init__(self, input_dim=5, output_dim=19, hidden_dim=128, dropout_rate=0.15):  
        super(ModelloSurrogato, self).__init__()  
  
        # 1. Strato di proiezione in ingresso: 5 input --> 128 feature latenti  
        self.input_layer = nn.Sequential(  
            nn.Linear(input_dim, hidden_dim),  
            nn.GELU()  
        )  
  
        # 2. Blocco residuo (stessa dimensionalità in input e output)  
        self.linear1 = nn.Linear(hidden_dim, hidden_dim)  
        self.gelu1 = nn.GELU()  
  
        self.linear2 = nn.Linear(hidden_dim, hidden_dim)  
        self.gelu2 = nn.GELU()  
  
        # 3. Regolarizzazione Dropout  
        self.dropout = nn.Dropout(dropout_rate)  
  
        # 4. Strato di proiezione in uscita: 128 --> 19 output (target fisici)  
        self.output_layer = nn.Linear(hidden_dim, output_dim)  
  
        # Il metodo forward mappa esplicitamente la topologia della rete,  
        # gestendo la biforcazione e il ricongiungimento dei tensori.  
  
    def forward(self, x):  
        # 1. Proiezione nello spazio latente  
        x_hidden = self.input_layer(x)  
  
        # 2. Salvataggio del tensore per la skip connection  
        residual = x_hidden  
  
        # 3. Elaborazione attraverso il blocco intermedio  
        out = self.gelu1(self.linear1(x_hidden))  
        out = self.linear2(out)  
  
        # 4. Ricongiungimento (somma vettoriale element-wise) e attivazione  
        out = self.gelu2(out+residual)  
  
        # 5. Regolarizzazione finale e proiezione agli output  
        out = self.dropout(out)  
        return self.output_layer(out)
```


MODELLO 2: SPLIT DETERMINISTICO

Ottimizzazione degli iperparametri e delle risorse computazionali



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

USO DI OPTUNA

- **Ricerca automatica iperparametri:** Optuna determina la miglior combinazione dei pesi e del learning rate del modello
- **Weight collapse:** Per non permettere di collassare verso combinazioni banali si usa una loss basata sul MSE non pesato
- **Pruning:** Per garantire efficienza computazionale, è stato inserito un **Median Pruner** che ha il compito di tagliare le prove che non ottengono risultati promettenti nelle prime epoche

Iperparametro	Range
Cristallino, Retina, Cornea, Sclera	[0.5, 10.0]
Nervo Ottico, Tumore	[2.0, 20.0]
Deviazione standard	[0.1, 0.5]
Tempo di trattamento	[5.0, 30.0]
Learning rate	[10 ⁻⁵ , 10 ⁻²]

EARLY STOPPING: DEFINIZIONE

Lo scopo è facilitare il lavoro di predizione del modello.

L'interpolazione avviene dopo che il modello a imparato a descrivere configurazioni vicine a quella che deve predire.

Ogni posizione angolare sull'occhio è ispezionata omogeneamente.

EARLY STOPPING: IMPLEMENTAZIONE NEL CODICE

```
class EarlyStopping:

    def __init__(self, patience=15, min_delta=1e-4):

        # patience: epoche da attendere
        self.patience = patience
        # min_delta: variazione minima
        self.min_delta = min_delta
        self.counter = 0
        self.best_loss= float('inf')
        self.early_stop = False

    def __call__(self, val_loss):
        if val_loss < self.best_loss - self.min_delta:
            self.best_loss = val_loss
            self.counter = 0 # Azzerà il contatore della pazienza
        else:
            self.counter += 1
            # Se la pazienza è esaurita, attiva il flag di stop
            if self.counter >= self.patience:
                self.early_stop = True
```

IMPLEMENTAZIONE NEL CODICE

```
criterion_eval = nn.MSELoss() # Metrica "pura" per Optuna
criterion_trial = CustomWeightedMSELoss(pesi_trial, device)
optimizer_trial = torch.optim.Adam(model_trial.parameters(),
                                   lr=learning_rate)

scheduler_trial = torch.optim.lr_scheduler.ReduceLROnPlateau(
    optimizer_trial, mode='min', factor=0.5, patience=7)

early_stopper_trial = EarlyStopping(patience = 20)
max_epochs_trial = 200
best_val_metric_trial = float('inf')

# 4. Loop di addestramento del singolo trial
for epoch in range(max_epochs_trial):
    model_trial.train()
    for bX, by in train_loader:
        bX, by = bX.to(device), by.to(device)
        optimizer_trial.zero_grad()
        loss = criterion_trial(model_trial(bX), by)
        loss.backward()
        optimizer_trial.step()
    model_trial.eval()
    val_metric_epoch = 0.0
    with torch.no_grad():
        for bX, by in val_loader:
            predizioni = model_trial(bX)
            val_metric_epoch += criterion_eval(
                predizioni, by).item()*bX.size(0)

    val_metric_epoch /= len(val_loader.dataset)

    if val_metric_epoch < best_val_metric_trial:
        best_val_metric_trial = val_metric_epoch

    scheduler_trial.step(val_metric_epoch)


    trial.report(val_metric_epoch, epoch)
    if trial.should_prune():
        raise optuna.exceptions.TrialPruned()

    early_stopper_trial(val_metric_epoch)
    if early_stopper_trial.early_stop:
        print(f"Early Stopping attivato all'epoca {epoch}! Ripristino i pesi migliori.")
        break

    return best_val_metric_trial

=====
OTTIMIZZAZIONE COMPLETATA
=====
Miglior Val loss: 0.006031
Parametri ottimali:
w_tempo: 6.134305
w_cristallino_m: 0.927557
w_cristallino_x: 0.548654
w_retina_m: 9.532150
w_retina_x: 0.598836
w_cornea_m: 9.800740
w_cornea_x: 9.865996
w_nervo_m: 7.259272
w_nervo_x: 18.542746
w_sclera_m: 5.825044
w_sclera_x: 9.430871
w_tumore_m: 14.151553
w_tumore_x: 18.794264
w_std_factor: 0.293343
learning_rate: 0.001522
=====
```

MODELLO 2: SPLIT DETERMINISTICO



Task 1: Risultati dell'addestramento e predizioni dei parametri di trattamento



SCELTE DI TRAINING

- **Utilizzo dei pesi ottimizzati:** L'algoritmo minimizza gli errori sugli organi più critici
- **Weight Decay:** Inserito direttamente in Adam costringe la rete a distribuire in modo omogeneo l'addestramento su tutti i neuroni
- **Early Stopping & Checkpointing:** I pesi sono salvati solo se c'è stato un miglioramento, in caso di non miglioramento continuo viene terminato l'allenamento e ripristinati i pesi migliori


PARAMETRI DELLA FASE DI TRAINING

Iperparametro	Configurazione
Ottimizzatore	Adam
Learning rate iniziale	$\eta_0 = 0.001522$
Weight decay	$\lambda = 10^{-4}$
Batch size	128
Numero massimo di epoche	500
Scheduler	ReduceLRonPlateau
Fattore di riduzione del learning rate	0.8
Patience dello scheduler	7 epoche
Dropout	$p = 0.15$
Funzione di loss	MSE pesata personalizzata


LEARNING CURVES




LEARNING CURVES: ASPETTI GENERALI




CONVERGENZA: 10-12 epoche



NO OVERFITTING: Validation e Train Loss allineate




GENERALIZZAZIONE: Dropout e Data Augmentation



PLATEAU: Quando la Loss diventa piatta interviene l'Early Stopping


MODELLO 2: SPLIT DETERMINISTICO

Task 1: Risultati dell'addestramento e predizioni dei parametri di trattamento




PREDIZIONE SULLA DOSE MEDIA

Performance del Modello Surrogato: DOSE MEDIA (Gy)




ACCURATEZZA E LINEARITÀ

Le predizioni si allineano lungo la bisettrice per tutte le 6 strutture anatomiche



ROBUSTEZZA


le predizioni non presentano segni evidenti di saturazioni pur con ordini di grandezza altamente variabili




OTTIME PRESTAZIONI SULLA PREDIZIONE DEL TUMORE

MODELLO 2: SPLIT DETERMINISTICO

Task 1: Risultati dell'addestramento e predizioni dei parametri di trattamento




PREDIZIONE SULLA DOSE MASSIMA



ACCURATEZZA E LINEARITÀ


Le predizioni sono allineate a $y=x$ anche con un parametro intrinsecamente più complesso



INCERTEZZA RIDOTTA E RISPOSTA FISICA COERENTE


MODELLO 2: SPLIT DETERMINISTICO

Task 1: Risultati dell'addestramento e predizioni dei parametri di trattamento




CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

PREDIZIONE SUL TEMPO DI TRATTAMENTO




BUONA PRECISIONE PER TEMPI MEDIO-BREVI
Incertezze maggiori solo per lunghe durate terapeutiche



MONOTONIA E COERENZA
L'andamento monotono dimostra una buona approssimazione del modello


MODELLO 2: SPLIT DETERMINISTICO

Task 1: Risultati dell'addestramento e predizioni dei parametri di trattamento



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

METRICHE D'ERRORE: MAE E MAPE



L'analisi degli errori assoluti (MAE) e percentuali (MAPE) rappresenta la validazione definitiva della solidità del modello surrogato. Il grafico del MAPE, in particolare, è cruciale: contestualizza l'errore assoluto dimostrando che, **anche dove il MAE appare numericamente elevato, l'errore relativo rimane ampiamente sotto controllo**. Questo conferma una **profonda comprensione** della complessa fisica sottostante, garantendo stime affidabili per tutte le strutture anatomiche, indipendentemente dal loro ordine di grandezza.

PRINCIPALI RISULTATI DEL MODELLO



BUONA ACCURATEZZA

Il modello stima bene le dosi medie mantenendo un $MAPE < 10\%$ per ogni tessuto



INVARIANZA DI SCALA

Il modello riesce a gestire molto bene parametri con range dinamici radicalmente diversi



IL MODELLO RAPPRESENTA UN SURROGATO AD ALTA FEDELTA'

MODELLO 2: SPLIT DETERMINISTICO

Task 2: Ottimizzazione della Posizione Chirurgica

Task 2a: Ricerca Discreta


- Esplorazione su Griglia Discreta ($\Delta\theta=5^\circ$):
- Analisi Vincoli Clinici:** Su 72 nodi angolari analizzati, **8 configurazioni** rispettano tutti i limiti di radioprotezione definiti per gli OAR.
 - Configurazione Ottimale:**
Angolo ottimale: $\theta=0^\circ$
Tempo predito = 6.38 giorni
Score Max OAR (tot) = 11.137

Organo	Dose Predetta (Gy)	Soglia Clinica (Gy)
Cristallino	0.56	5.0
Retina	27.98	45.0
Cornea	2.35	50.0
Nervo Ottico	9.12	55.0
Sclera	48.47	100.0

Task 2b: Ottimizzazione Continua Differenziabile

- Raffinamento Continuo Gradient-Based (Multi-Start):
- Esplorazione Spazio delle Soluzioni:** L'ottimizzazione parte da 4 angoli indipendenti ($0^\circ, 90^\circ, 180^\circ, 270^\circ$).
 - Penalizzazione Vincoli:** I percorsi da $90^\circ, 180^\circ, 270^\circ$ cadono in regioni ad altissima penalità ($L_{tot}>10^7$).


Start Angle (θ_0)	Angolo Finale (θ^*)	L_{tot}	Esito / Note
0°	$359.52^\circ (-0.48^\circ)$	11.1062	Minimo Globale
90°	55.40°	5.67×10^7	Violazione vincoli
180°	179.35°	6.27×10^{11}	Violazione vincoli
270°	307.97°	5.77×10^7	Violazione vincoli



MODELLO 2: SPLIT DETERMINISTICO

Task 3: Analisi di Robustezza e Incertezza Stocastica

Task 3a: Incertezza Continua (MC Dropout)



Parametro	Valore
Media θ	1.04°
Incertezza σ	± 5.01
Intervallo al 95% CI	$[-8.78^\circ, 10.86^\circ]$

Task 3b: Robustezza Discreta (1000 Iterazioni)

Angolo Discreto (θ)	Frequenza di Vittoria (%)	Iterazioni Stocastiche
0°	35.1%	351
5°	28.9%	289
355° (-5°)	25.2%	252
350° (-10°)	7.6%	76
10°	3.0%	30


- Dominanza del Settore Simmetrico:** L'angolo $\theta=0$ è la singola posizione più frequente (35.1%). Considerando l'intorno di tolleranza tra -5 e $+5$ ($-5,0,5$), la confidenza cumulativa raggiunge l'89.2% (892 iterazioni su 1000).
- Affidabilità Chirurgica:** Il posizionamento ad angolo nullo non è solo l'ottimo nominale deterministico, ma rappresenta la scelta terapeutica più robusta e sicura a fronte dell'incertezza stocastica del modello.




PROBLEMA:
QUANTIFICAZIONE DELL'INCERTEZZA



COERENZA ELEVATA: I RISULTATI CADONO
IN UN RANGE RISTRETTO




TRADUZIONE DELL'INCERTEZZA IN UN
MARGINE FISICO-CLINICO



L'APPROCCIO COMBINATO TRADUCE
L'OTTIMO TEORICO ALL'OTTIMO CLINICO


MODELLO 3: SPLIT ANGOLARE CONTINUO

Stress test Leave-Sector-Out e diagnostica della dipendenza angolare



DEFINIZIONE DELLO SPLIT

- **Split angolare continuo Leave-Sector-Out:**
- il settore **vicino al tumore** ($\pm 45^\circ$) è escluso da **Training e Validation**
- Vine utilizzato solo nella fase di **Test**
- Aiuta a valutare la capacità del modello di **estrapolare** in una regione rilevante non vista durante l'addestramento.



Sottoinsieme	N.	Dominio angolare
Training	42	$d_{\text{circ}}(\theta, 0) > 45^\circ$
Validation	11	1 su 5 con nel settore lontano
Test	19	$d_{\text{circ}}(\theta, 0) \leq 45^\circ$

IDEA METODOLOGICA

Lo scopo è sottoporre il modello a uno **stress test out-of-distribution**.

La selezione del modello avviene esclusivamente nel settore conosciuto;

il settore vicino al tumore viene utilizzato soltanto per la valutazione finale.

DIPENDENZA ANGOLARE DI PRIMO ORDINE

Per ciascun output dosimetrico viene adattato, sul solo training set, un modello armonico di primo ordine nelle coordinate periodiche $\sin\theta$ e $\cos\theta$

$$y_k(\theta) \simeq \beta_{0,k} + \beta_{\sin,k} \sin \theta + \beta_{\cos,k} \cos \theta$$
$$\theta_k^* = \text{atan2}(\beta_{\sin,k}, \beta_{\cos,k})$$

- Lo split separa la selezione del modello dalla valutazione:
- **La validation misura l'interpolazione locale** nel settore noto.
- **Il test quantifica la capacità di estrapolare** verso il tumore.

IMPLEMENTAZIONE NEL CODICE

```
#COSTRUZIONE DELLO SPLIT
theta_deg = np.mod(
    np.degrees(
        np.arctan2(X[:, 0], X[:, 1])
    ),
    360.0
)

dist_da_zero = np.minimum(
    theta_deg,
    360.0 - theta_deg
)

mask_test = dist_da_zero <= 45.0
idx_test = np.flatnonzero(mask_test)

idx_far = np.flatnonzero(~mask_test)
idx_far = idx_far[np.argsort(theta_deg[idx_far])]

mask_val = np.arange(idx_far.size) % 5 == 0
idx_val = idx_far[mask_val]
idx_train = idx_far[~mask_val]

#DIAGNOSTICA ANGOLARE
X_ang = np.column_stack([
    sin_theta[idx_train],
    cos_theta[idx_train]
])

reg = LinearRegression()
reg.fit(X_ang, valori_output)


R2 = reg.score(X_ang, valori_output)

beta_sin, beta_cos = reg.coef_
ampiezza = np.hypot(beta_sin, beta_cos)

direzione = np.degrees(
    np.arctan2(beta_sin, beta_cos)
) % 360.0
```


MODELLO 3: SPLIT ANGOLARE CONTINUO

Architettura della rete




SCELTE NELL'ARCHITETTURA

- Architettura: **MLP sequenziale**
- Struttura: **5→64→32→19**
- Attivazione: **GELU**
- Normalizzazione: **LayerNorm**
- Regularizzazione: **Dropout p=0.15**
- Output: layer lineare a **19** unità
- Parametri allenabili: **3.283**
- Obiettivo: regressione **multi-output differenziabile**

LayerNorm invece di **BatchNorm**: più stabile con batch size ridotti e dati tabulari, non dipende dalle statistiche di batch

GELU invece di **ReLU**: transizione più morbida, evita neuroni "morti" e migliora il flusso del gradiente

ARCHITETTURA DELLA RETE



MONTECARLO DROP OUT

- Dropout mantenuto attivo durante l'inferenza
- **500 forward pass** stocastici per ogni campione
- Stima della **media** predetta e della **deviazione standard**
- Riduzione delle fluttuazioni nella stima dell'incertezza
- Particolarmente utile nel test OOD near-tumor
- **σ MC**: indicatore dell'incertezza epistemica

IMPLEMENTAZIONE NEL CODICE

```
# PREPROCESSING E ARCHITETTURA DEL MODELLO

# Target: log1p + standardizzazione
y_train_log = np.log1p(y_train)
y_val_log   = np.log1p(y_val)

scaler_y = StandardScaler()
y_train_scaled = scaler_y.fit_transform(y_train_log)
y_val_scaled   = scaler_y.transform(y_val_log)

# Input: standardizzazione della sola coordinata radiale
X_train_scaled = X_train.copy()
X_val_scaled   = X_val.copy()
X_test_scaled  = X_test.copy()

scaler_X = StandardScaler()
X_train_scaled[:, 4:] = scaler_X.fit_transform(X_train[:, 4:])
X_val_scaled[:, 4:]   = scaler_X.transform(X_val[:, 4:])
X_test_scaled[:, 4:]  = scaler_X.transform(X_test[:, 4:])

# :

N_INPUT = 5
N_OUTPUT = 19
DROPOUT_RATE = 0.15

class ModelloSurrogato(nn.Module):

    def __init__(self):
        super().__init__()

        self.rete = nn.Sequential(
            nn.Linear(N_INPUT, 64),
            nn.GELU(),
            nn.LayerNorm(64),
            nn.Dropout(DROPOUT_RATE),

            nn.Linear(64, 32),
            nn.GELU(),
            nn.LayerNorm(32),
            nn.Dropout(DROPOUT_RATE),

            # Output nello spazio log-standardizzato
            nn.Linear(32, N_OUTPUT)
        )

    def forward(self, x):
        return self.rete(x)
```

MODELLO 3: SPLIT ANGOLARE CONTINUO



Funzione di Loss, Iperparametri e addestramento del modello

FUNZIONE DI LOSS MULTI-OUTPUT

19 OUTPUT: TEMPO IRRADIAZIONE + 18 QUANTITÀ DOSIMETRICHE

- **log1p** → riduce asimmetria e scale
- **STANDARDIZZAZIONE** → evita dominanza degli output più grandi

$$\tilde{y}_j = \frac{\log(1 + y_j) - \mu_{j,\text{train}}}{\sigma_{j,\text{train}}}$$

- **Loss: MSE multi-output, pesi normalizzati**
- **Pesi uniformi ($w_j=1$)** → nessuna priorità nello spazio log-standardizzato

$$\mathcal{L} = \frac{1}{B} \sum_{b=1}^B \frac{\sum_{j=1}^{19} w_j \left(\hat{y}_{b,j} - \tilde{y}_{b,j} \right)^2}{\sum_{j=1}^{19} w_j}$$

- **Train e validation: stesso settore angolare**
- **Pesare la loss sulla validation** → i pesi rifletterebero solo le caratteristiche di quel settore
- **Rischio: pesi non validi** nel settore vicino al tumore
- **PESI UNIFORMI** → EVITANO QUESTO BIAS

LOGICA DI ADDESTRAMENTO

- **Adam + weight decay**: ottimizzazione stabile con regolarizzazione dei parametri.
- **ReduceLROnPlateau**: dimezza il learning rate dopo 25 epoche senza miglioramenti della validation loss.
- **Early stopping**: interrompe il training dopo 60 epoche senza miglioramenti e ripristina il modello migliore.
- **Data augmentation ×30**: applicata solo al Training Set.

Iperparametro	Configurazione
Ottimizzatore	Adam
Learning rate iniziale	$\eta_0 = 10^{-3}$
Weight decay	$\lambda = 10^{-4}$
Batch size	16
Numero massimo di epoche	500
Scheduler	ReduceLROnPlateau
Fattore di riduzione del learning rate	0.5
Patience dello scheduler	25 epoche
Learning rate minimo	$\eta_{\min} = 10^{-6}$
Early stopping	Patience = 60 epoche
Miglioramento minimo	$\Delta_{\min} = 10^{-5}$
Data augmentation	×30, $\sigma_\theta = 1^\circ$
Dropout	$p = 0.15$
Funzione di loss	MSE multi-output, $w_j = 1$

IMPLEMENTAZIONE NEL CODICE

```
# =====  
# LOSS MULTI-OUTPUT - PESI UNIFORMI  
# =====  
  
LOSS_WEIGHTS = torch.ones(  
    N_OUTPUT,  
    dtype=torch.float32,  
    device=device  
)  
  
def multioutput_mse(pred, target):  
  
    errore_quadratico = (pred - target).pow(2)  
  
    loss_per_campione = (  
        errore_quadratico * LOSS_WEIGHTS  
    ).sum(dim=-1) / LOSS_WEIGHTS.sum()  
  
    return loss_per_campione.mean()  
  
criterion = multioutput_mse  
  
# =====  
# IPERPARAMETRI DI ADDESTRAMENTO  
# =====  
  
LEARNING_RATE = 1e-3  
WEIGHT_DECAY = 1e-4  
MAX_NUM_EPOCHS = 500  
  
SCHEDULER_FACTOR = 0.5  
SCHEDULER_PATIENCE = 25  
MIN_LEARNING_RATE = 1e-6  
  
EARLY_STOPPING_PATIENCE = 60  
MIN_DELTA = 1e-5  
  
# =====  
# OTTIMIZZATORE E SCHEDULER  
# =====  
  
optimizer = torch.optim.Adam(  
    modello.parameters(),  
    lr=LEARNING_RATE,  
    weight_decay=WEIGHT_DECAY  
)  
  
scheduler = torch.optim.lr_scheduler.ReduceLROnPlateau(  
    optimizer,  
    mode="min",  
    factor=SCHEDULER_FACTOR,  
    patience=SCHEDULER_PATIENCE,  
    min_lr=MIN_LEARNING_RATE  
)
```


MODELLO 3: SPLIT ANGOLARE CONTINUO

Metriche e Learning Curves

DINAMICA DI ADDESTRAMENTO


Convergenza rapida nelle prime epoche (train e val loss)

- **Plateau** → scheduler riduce il learning rate
- **Early stopping a 369 epoche** → ripristinati i parametri migliori

$$e_{\text{best}} = 309, \quad \mathcal{L}_{\text{val},\text{min}} = 0.0170 \quad \frac{\mathcal{L}_{\text{train}}^{\text{final}}}{\mathcal{L}_{\text{val}}^{\text{final}}} \approx 1.98$$

- **Training loss > validation loss**
- Atteso: training con Dropout + Data Augmentation, validation deterministica
- Nessuna divergenza tipica da overfitting

LE LEARNING CURVES VERIFICANO LA CONVERGENZA IN-DOMAIN, MA NON DIMOSTRANO L'AFFIDABILITÀ NEL SETTORE NEAR-TUMOR



VALUTAZIONE QUANTITATIVA SUI DATI DI TEST

METRICHE (UNITÀ FISICHE: GIORNI, GY)

- **MAE** → errore assoluto, cresce con la scala del target
- **MAPE** → errore relativo, penalizza i valori reali molto bassi

MAE e MAPE non ne descrivono direzione e struttura. Bias e R^2 permettono quindi di valutare sovrastima, capacità predittiva e affidabilità dell'incertezza.



INTERPRETAZIONE

- Nel settore near-tumor, cornea e nervo ottico ricevono dosi molto basse; il modello non ricostruisce completamente questa riduzione e tende a sovrastimarle, tuttavia **il tumore è l'organo meglio estrapolato:**

$$\text{MAPE}_{\text{mean}} = 13.45\%, \quad \text{MAPE}_{\text{max}} = 16.04\%$$








- Il fallimento OOD è soprattutto relativo: la sovrastima maggiore si osserva dove la dose reale è minima.

Output	Bias	R^2	σ_{MC}	Cop. 5–95%
Cristallino	+0.27	+0.041	1.03	100.0%
Retina	+34.16	-3.072	47.45	47.4%
Cornea	+6.81	-1.072	9.55	63.2%
Nervo ottico	+32.86	+0.223	54.28	57.9%
Sclera	+70.86	-2.470	93.09	52.6%
Tumore	-4.41	-1.216	7.28	100.0%
Tempo	+2.23	-1.919	5.82	100.0%



MODELLO 3: SPLIT ANGOLARE CONTINUO

Risultati della task 1: Dose Media



COMMENTI DOSE MEDIA








- Per tutte le strutture la dose media è sistematicamente **sovrastimata**
- **CRISTALLINO** è il miglior output per le metriche anche se la variabilità assoluta non viene ricostruita
- **NERVO OTTICO** è il meno degradato tra gli OAR ($R^2 = 0.223$): parte dell'andamento angolare sopravvive
- **LA STRUTTURA RELATIVA TRA CONFIGURAZIONI È CONSERVATA, LA SCALA ASSOLUTA NO**
- **TUMORE** è l'unico output sottostimato sulla dose media con R^2 comunque negativo

ANALISI DELLA STRUTTURA A DOPPIO RAMO

- Dal training è escluso il settore near-tumor (angoli attorno a $\theta = 0^\circ$)
- Quel settore è raggiunto da due lati: da $\theta > 0^\circ$ che scende verso 0° e da $\theta < 0^\circ$ che sale verso 0°
- La rete estrapola nel buco da entrambi i lati → due estrapolazioni separate → due rami
- I due rami restano ordinati: la struttura angolare è conservata e le configurazioni $\pm\theta$ vengono distinte (asimmetria anatomica dell'occhio)

MODELLO 3: SPLIT ANGOLARE CONTINUO

Risultati della task 1: Dose Massima



COMMENTI DOSE MAX

- Per tutte le strutture prevale una sovrastima della dose massima.
- **RETINA e SCLERA** mostrano le prestazioni peggiori nella ricostruzione della variabilità.
- **NERVO OTTICO**: parte dell'andamento tra configurazioni viene riprodotta:

$$R^2_{\text{nervo}} = 0.328$$

- **TUMORE**: migliore risultato dell'intera analisi, pur con una sovrastima media non trascurabile

$$R^2_{\text{tumore}} = 0.711, \quad \text{Bias} = +40.17 \text{ Gy}$$


- **LA DOSE MASSIMA AL TUMORE È L'UNICO OUTPUT PER CUI IL MODELLO RIPRODUCE IN MODO APPREZZABILE LA VARIABILITÀ.**

DOPPIO RAMO ANCORA PRESENTE



- **DOPPIO RAMO ANCORA PRESENTE** → non dipende dalla metrica, ma dallo splitting
- **CAUSA**: settore near-tumor escluso → lacuna a $\theta = 0^\circ$ estrapolata da due lati ($\theta > 0^\circ$ e $\theta < 0^\circ$)
- Comportamento tipico delle strutture asimmetriche rispetto al settore di test

MODELLO 3: SPLIT ANGOLARE CONTINUO

Risultati della task 1: Tempo di Trattamento



Predizione del tempo di irradiazione (predizione centrale: deterministica)



COMMENTI TEMPO DI TRATTAMENTO

- La vicinanza tra MAE e RMSE indica errori di ampiezza abbastanza uniforme, non dominati da pochi campioni anomali: RMSE = 2.26 giorni

MAE = 2.23 giorni, Bias = +2.23 giorni

- Il coefficiente negativo evidenzia una scarsa capacità di ricostruire quantitativamente la variabilità OOD:

$$R^2 = -1.919, \quad \sigma_{t, \text{Geant4}} = 1.36 \text{ giorni}$$

- Il modello conserva l'organizzazione angolare del tempo, ma introduce una sovrastima sistematica nel settore near-tumor.

COMMENTO FINALE

Nessuna delle tre metriche è affidabile in valore assoluto: in regime di forte estrapolazione il modello non è adatto alla pianificazione dosimetrica, e va usato solo per confrontare e ordinare le configurazioni, non per quantificare la dose.

Output	Bias	R^2	Comportamento
Tempo	+2.23 gg	-1.919	sovrastima generale
Dose media	da +0.27 a +70.86 Gy	da +0.04 a -3.07	sovrastima (tumore -4.41, sotto)
Dose massima	da +8.50 a +1121 Gy	da -2.70 a +0.71	sovrastima; tumore $R^2 = 0.71$

MODELLO 3: SPLIT ANGOLARE CONTINUO

TASK 2: Selezione della posizione angolare della placca

TASK 2a: GRID SERACH

VALUTAZIONE SULLA GRIGLIA (72 ANGOLI, $\Delta\theta=5^\circ$)

- Per ogni angolo si costruisce un nuovo input: **solo θ cambia**
- Preprocessing identico al training;
- IL MODELLO PREDICE, PER OGNI ANGOLO: **TEMPO DI IRRADIAZIONE + DOSI MEDIE E MASSIME AGLI ORGANI**
- Escluse le configurazioni con predizioni negative o non finite (non fisiche)

SELEZIONE

- **Ammissibile solo se rispetta simultaneamente il limite sul tempo e tutti i limiti sulle dosi medie agli OAR**
- Le ammissibili vengono ordinate con uno score basato sulle dosi massime normalizzate

LIMITI DELLA PROCEDURA

- **È una ricerca discreta**: sceglie solo tra i 72 angoli della griglia, senza interpolare soluzioni intermedie
- Se nessuna configurazione soddisfa tutti i vincoli, l'insieme ammissibile resta vuoto e non si forza una scelta

RISULTATI

La ricerca su griglia non seleziona alcun angolo: le soglie hard risultano incompatibili con le predizioni ottenute in regime OOD.

$$\Theta_{\text{hard}} = \emptyset$$

TASK 2b: Hierarchical Ranking of Configurations

Configurazioni valutate

72 angoli • $\Delta\theta = 5^\circ$

0°

5°

10°

...

350°

355°

Indicatori normalizzati per ogni configurazione

$r_{\text{tempo}} = \text{tempo} / \text{tempo_min}$
 $r_{\text{OAR}} = \text{dose_media} / \text{limite}$ (per organo)

N. superamenti OAR = $(r_{\text{OAR}} > 1)$
Score eccesso OAR = $\sum \max(r_{\text{OAR}} - 1, 0)$
Peggior rapporto OAR = $\max r_{\text{OAR}}$

Classe tumorale (da r_{tempo})
A ≤ 1.05 B ≤ 1.10 C ≤ 1.25

Ordinamento lessicografico — gerarchia dei criteri

	Classe tumorale	A > B > C
1	N. superamenti OAR	minimo ↓
2	Score eccesso OAR	minimo ↓
3	Peggior rapporto OAR	minimo ↓
4	Score max OAR	minimo ↓
5	Tempo relativo	minimo ↓

A parità di un criterio si passa al successivo → ordine deciso in cascata

CANDIDATO PRIORITARIO
 $\theta^* = 0^\circ$ • Classe A

Pos.	θ (°)	Settore	Classe	Tempo (gg)	Tempo rel.	Tumore medio (Gy)
1	0	near-tumor	A	8.4152	1.0075	26.1028
2	355	near-tumor	A	8.5054	1.0183	26.5501
3	5	near-tumor	A	8.3644	1.0015	25.7863
4	350	near-tumor	A	8.6394	1.0344	27.1450
5	10	near-tumor	A	8.3522	1.0000	25.5931
6	15	near-tumor	A	8.3809	1.0034	25.5231
7	20	near-tumor	A	8.4570	1.0126	25.5852
8	25	near-tumor	A	8.5920	1.0287	25.7983
9	345	near-tumor	B	8.8260	1.0567	27.9147
10	340	near-tumor	B	9.0800	1.0871	28.9013

IMPLEMENTAZIONE NEL CODICE

```
# ===== TASK 2A - GRID SEARCH =====

angoli_gradi = np.arange(0, 360, 5)
angoli_rad = np.radians(angoli_gradi)

X_opt[:, 0] = np.sin(angoli_rad)
X_opt[:, 1] = np.cos(angoli_rad)
X_opt[:, 2] = sin_phi_fisso
X_opt[:, 3] = cos_phi_fisso
X_opt[:, 4] = raggio_fisso

pred_reale_opt = stimatori_opt[STIMATORE_CENTRALE]

maschera_vincoli = (
    (tempo_opt <= LIMITE_TEMPO)
    & (crist_media_opt <= LIMITE_MEDIA["crist"])
    & (retina_media_opt <= LIMITE_MEDIA["retina"])
    & (cornea_media_opt <= LIMITE_MEDIA["cornea"])
    & (nervo_media_opt <= LIMITE_MEDIA["nervo"])
    & (sclera_media_opt <= LIMITE_MEDIA["sclera"])
)

score_max_oar = sum(
    dose_max[organo] / LIMITE_MAX[organo]
    for organo in ORGANI_OAR
)

# ===== TASK 2B - RANKING GERARCHICO =====

rapporto_tempo = tempo_opt / tempo_opt.min()

rapporti_media = np.column_stack([
    dose_media[organo] / LIMITE_MEDIA[organo]
    for organo in ORGANI_OAR
])


numero_superamenti = np.sum(
    rapporti_media > 1.0,
    axis=1
)

score_eccesso = np.sum(
    np.maximum(rapporti_media - 1.0, 0.0),
    axis=1
)

peggior_rapporto = np.max(
    rapporti_media,
    axis=1
)

criteri_ranking = [
    "Ordine classe",
    "Numero superamenti OAR",
    "Score eccesso OAR",
    "Peggior rapporto OAR",
    "Score max OAR",
    "Tempo relativo"
]

df_ranking = df_candidati.sort_values(
    by=criteri_ranking
)
```



MODELLO 3: SPLIT ANGOLARE CONTINUO

Ottimizzazione continua della posizione angolare

WORKFLOW

Θ COME VARIABILE CONTINUA

- Non più vincolato ai 72 nodi: θ è un parametro ottimizzabile
- Codificato come $(\sin \theta, \cos \theta) \rightarrow$ periodicità garantita

PIPELINE DIFFERENZIABILE

- ϕ_0, r_0 fissi; varia solo θ
- Rete in eval, Dropout off $\rightarrow$ obiettivo deterministico
 $\theta \rightarrow \mathbf{x}(\theta) \rightarrow \tilde{\mathbf{x}}(\theta) \rightarrow f_{\text{NN}} \rightarrow \hat{\mathbf{y}}(\theta) \rightarrow \mathcal{J}(\theta)$


OTTIMIZZAZIONE MULTISTART

- Funzione Obiettivo minimizzato:
$$\mathcal{J} = \mathcal{J}_{\text{tempo}} + \mathcal{J}_{\text{OAR}} + \mathcal{J}_{\text{max}} + \mathcal{J}_{\text{fisica}}$$
- Il gradiente si propaga fino a θ : discesa diretta su $\mathcal{J}$
- Più angoli iniziali $\rightarrow$ evita i minimi locali
- Soluzioni riportate in $[0^\circ, 360^\circ)$, poi raggruppate

RISULTATI OTTIMIZZAZIONE


Metodo	θ (°)	$\mathcal{J}(\theta)$
Ottimo continuo (Adam)	4.0268	6.634474
Minimo griglia fine 0.1	4.0000	6.634480
Migliore griglia 5 (NN)	5	6.635690
Candidato Task 2B	0	6.654798
Migliore secondo Geant4	0	1.817607

L'ottimizzazione differenziabile converge a $\theta^* = 4.03^\circ$, a meno di 1° dal minimo della griglia fine: la ricerca continua e quella discreta sono coerenti entro i limiti del modello.




Il MC Dropout trasforma lastima puntuale in una distribuzione: media $\approx 4.15^\circ$ e zona $1\sigma \approx \pm 5.39^\circ$, cioè l'intervallo angolare entro cui l'ottimo resta stabile rispetto alla variabilità del modello.

CONCLUSIONI E PROSPETTIVE




MESSAGGIO CHIAVE



I modelli surrogati differenziabili rendono più rapida la pianificazione della brachiterapia oculare, riducendo l'onere computazionale delle simulazioni Monte Carlo e abilitando l'ottimizzazione continua della posizione della placca.


CONFRONTO DEI MODELLI

MODELLO 1




- MLP sequenziale
- Splitting random
- Prestazioni: elevata accuratezza in interpolazione su tempo, tumore e OAR;
- Configurazione migliore:
 $\theta \approx 0^\circ$

MODELLO 2



- MLP con skip connection, ottimizzata tramite Optuna
- Splitting deterministico
- Prestazioni: convergenza stabile e rapida, con buona propagazione del gradiente
- Configurazione migliore:
 $\theta \approx 0^\circ$

MODELLO 3



- MLP sequenziale
- Split angolare continuo, con esclusione del settore near-tumor
- Prestazioni: sovrastima delle dosi assolute
- Configurazione migliore:
 $\theta \approx 4,03^\circ$


TAKE HOME MESSAGES



**RICERCA
DISCRETA**



**OTTIMIZZAZIONE
CONTINUA**




**MONTECARLO
DROPOUT**




**PIANIFICAZIONE
PIÙ RAPIDA E
ROBUSTA**


PROSPETTIVE FUTURE



- **AMPLIARE IL DATASET DI SIMULAZIONI**
- **VARIARE SIA L'ANGOLO POLARE θ SIA L'ANGOLO AZIMUTALE ϕ**
- **ESPLORARE L'INTERO SPAZIO TRIDIMENSIONALE DELLE CONFIGURAZIONI**
- **RIDURRE GLI ERRORI NEL REGIME DI ESTRAPOLAZIONE**
- **INDIRIZZARE IL MODELLO VERSO UNA APPLICAZIONE CLINICA REALE**



Campionamento
angolare limitato




Campionamento
3D denso



IL PROSSIMO PASSO È ALLENARE IL MODELLO SU UNA GEOMETRIA PIÙ RICCA, PER OTTENERE STIME AFFIDABILI IN OGNI CONFIGURAZIONE SPAZIALE DELLA PLACCA.

GRAZIE PER L'ATTENZIONE



CENTRO NAZIONALE
PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE

RECAP

- **Dataset Geant4:** costruzione degli input geometrici e degli output dosimetrici.
- **Modello surrogato:** rete neurale differenziabile per predire tempo e dose.
- **Strategie di splitting:** random, sistematico e continuo angolare.
- Valutazione delle prestazioni: confronto tra predizioni e simulazioni Geant4.
- **Pianificazione inversa:** ricerca discreta e ranking delle configurazioni.
- **Ottimizzazione:** ricerca dell'angolo ottimale mediante gradiente.
- **Stima dell'incertezza:** Monte Carlo Dropout e regione di confidenza.
- **Limiti e prospettive:** estrapolazione e futura estensione allo spazio (θ, φ) .

