



CENTRO NAZIONALE
**PROTEZIONE DALLE RADIAZIONI
E FISICA COMPUTAZIONALE**



SAPIENZA
UNIVERSITÀ DI ROMA

IRIDE

**Innovative RadIation Dose Estimation for Pediatric Retinoblastoma Treatment
Enhancement**

Sviluppo di un modello surrogato differenziabile delle simulazioni
Monte Carlo per la stima della distribuzione di dose in brachiterapia oculare

Autori

Simone Nardi
Emanuele Pinci
Caterina Sacchi

Collaborazione

Sapienza Università di Roma
Istituto Superiore di Sanità

Indice

1	Introduzione	3
2	Task 0: Manipolazione dei dati grezzi e creazione del dataset	4
2.1	Costruzione dei Tensori di Input e Output	4
3	Strategia Metodologica e Flusso di Lavoro	7
3.1	Panoramica della Strategia e Flusso di Lavoro	7
3.2	Vincoli Clinici di Dose	7
3.3	Approcci Modellistici e Strategie di Splitting del Dataset	7
4	Task 1: Creazione e Valutazione dei Modelli Surrogati	9
4.1	Introduzione	9
4.2	Metodologia Generale e Componenti Comuni	9
4.3	Modello 1: MLP Sequenziale con Splitting Random	11
4.4	Modello 2: MLP con Skip Connection e Splitting Sistemático	15
4.5	Modello 3: MLP Sequenziale con Split Angolare Continuo	19
5	Pianificazione Inversa, Ottimizzazione Geometrica e Valutazione di Robustezza	25
5.1	Task 2: Ottimizzazione del Posizionamento della Placca (Discreta e Differenziabile)	25
5.2	Task 3	25
5.3	Risultati del MLP Sequenziale con Splitting Random	26
6	Confronto, conclusioni e obiettivi futuri	33

1 Introduzione

Il retinoblastoma è un tumore maligno primario della retina che viene diagnosticato nella quasi totalità dei casi in età pediatrica, principalmente nei primi 24 mesi di vita, con un'incidenza in Italia di un caso ogni 20.000 nascite. I trattamenti standard per questa patologia includono solitamente cicli combinati di chemioterapia, trattamenti focali dell'occhio con laser e crioterapia. Tuttavia, se localizzato in specifiche aree, questo tumore risulta particolarmente sensibile alla brachiterapia, una tecnica che prevede l'applicazione di una placca radioattiva (come quelle in Rutenio-106) a contatto con l'occhio. L'impiego di questa terapia ha aumentato significativamente il tasso di successo nella preservazione oculare, limitando le enucleazioni. In questo contesto si inserisce il progetto IRIDE (Innovative Radiation Dose Estimation for pediatric retinoblastoma treatment enhancement). Nonostante la sua efficacia, la brachiterapia è ancora un piano di trattamento di seconda linea e dunque, in IRIDE, l'obiettivo è migliorare la brachiterapia per il retinoblastoma pediatrico affinché possa diventare un'opzione terapeutica di prima linea.

La causa principale per cui questo tipo di trattamento non è ancora la prima scelta clinica è la mancanza di un controllo adeguato e rapido sulla dose somministrata ai tessuti.

Attualmente, lo sviluppo di un piano di trattamento richiede la caratterizzazione 3D dell'intera placca e l'utilizzo di accurate, ma lente, simulazioni Monte Carlo (eseguite tramite software come Geant4) su un modello computazionale dell'occhio voxelizzato. Dato che l'ottimizzazione del piano richiede di testare innumerevoli configurazioni per bilanciare l'efficacia sul tumore e la salvaguardia dei tessuti sani, l'approccio Monte Carlo standard risulta computazionalmente troppo oneroso.

In questo contesto l'utilizzo del Machine Learning potrebbe risultare particolarmente interessante per alleggerire il costo computazionale della caratterizzazione preliminare e dello sviluppo del piano di trattamento clinico. Infatti, emerge la necessità di costruire un modello surrogato differenziabile della simulazione del piano di trattamento. In prima approssimazione, il modello sarà capace di stimare in modo estremamente più rapido le distribuzioni di dose a partire dalla posizione della placca. Sfruttando i profili di dose ricostruiti, il modello sarà in grado di aiutare il team medico nel processo decisionale. Infatti, il modello potrà valutare la miglior posizione della placca integrando le informazioni di base per il trattamento come: la geometria voxelizzata dell'occhio, la posizione del tumore, l'attività della sorgente radioattiva posta sulla placca e i vincoli medici per la salvaguardia dei tessuti sani.

Il presente elaborato illustra le fasi di sviluppo e validazione del progetto come segue:

- **Sezione 2:** descrizione della fase preliminare di esplorazione e organizzazione del dataset a partire dai dati grezzi;
- **Sezione 3:** presentazione generale della strategia di sviluppo adottata;
- **Sezione 4:** esposizione degli obiettivi e dei risultati della prima fase del progetto;
- **Sezione 5:** analisi dei risultati principali dell'intero progetto e dei metodi utilizzati per il loro raggiungimento;
- **Sezione 6:** sintesi dei traguardi raggiunti e discussione dei possibili sviluppi futuri del progetto IRIDE.

2 Task 0: Manipolazione dei dati grezzi e creazione del dataset

2.1 Costruzione dei Tensori di Input e Output

L'obiettivo principale della Task 0 è elaborare i dati grezzi prodotti dalle simulazioni Monte Carlo effettuate in Geant4 trasformandoli in array multidimensionali strutturati (tensori), idonei all'addestramento dei modelli di Machine Learning. I dataset di partenza rappresentano le distribuzioni di dose voxelizzate all'interno di una geometria oculare affetta da retinoblastoma durante un trattamento di brachiterapia oculare con placca di Rutenio-106 (^{106}Ru). Un estratto tipico della struttura dati dei file di output Geant4 è riportato in Tabella 2.1.

voxelId	organId	x [mm]	y [mm]	z [mm]	dose [Gy/evento]	n_contributi
37833	9000	1.75	0.25	-9.75	1.412504e-13	699
37834	9000	2.25	0.25	-9.75	7.433572e-14	275
37835	1418	2.75	0.25	-9.75	0.000000e+00	0
37836	1418	3.25	0.25	-9.75	2.010501e-13	803
37837	1415	3.75	0.25	-9.75	3.065792e-13	1312

Tabella 2.1: Estratto della matrice di dati di dose per voxel ricavata dalla simulazione.

Preprocessing ed Estrazione delle Feature Geometriche

Per ciascuna configurazione, le simulazioni sono state eseguite ruotando il centro della placca lungo angoli sferici $\theta \in [0^\circ, 355^\circ]$ a passi di 5° (mantenendo fisso $\phi = 0^\circ$). Per garantire la stabilità numerica e una rappresentazione continua adatta alle reti neurali, le coordinate angolari non sono state inserite come angoli grezzi, bensì parametrizzate tramite trasformazioni trigonometriche:

$$\mathbf{x}_{\text{rot}} = [\sin(\theta), \cos(\theta), \sin(\phi), \cos(\phi)] \quad (2.1)$$

La posizione del centro della placca (modellata geometricamente come una calotta emisferica) e quella del centro dell'occhio non coincidevano a priori nell'origine del sistema di riferimento. Di conseguenza, nella prima riga di ciascun file .txt delle simulazioni sono riportate le coordinate spaziali effettive del centro della placca $(x_{\text{placca}}, y_{\text{placca}}, z_{\text{placca}})$.

A partire da tali coordinate, è stata inizialmente calcolata la distanza euclidea tra il centro dell'occhio e il centro della placca. Per ottenere la posizione radiale effettiva della superficie esterna/attiva della placca rispetto al centro dell'occhio è stato sommato il raggio di curvatura interno della placca $R_{\text{placca}} = 12.1$ mm:

$$r_{\text{totale}} = \sqrt{x_{\text{placca}}^2 + y_{\text{placca}}^2 + z_{\text{placca}}^2} + R_{\text{placca}} \quad (2.2)$$

In questo modo, ogni vettore $\mathbf{x}_i \in \mathbb{R}^5$ risulta univocamente definito da feature sia rotazionali sia traslazionali:

$$\mathbf{x}_i = [\sin(\theta), \cos(\theta), \sin(\phi), \cos(\phi), r_{\text{totale}}] \quad (2.3)$$

Identificazione della Regione Apicale e Calcolo del Tempo di Esposizione

Per calcolare tempi di esposizione e dosi integrate clinicamente realistici, la durata del trattamento $T_{\text{trattamento}}$ (espressa in giorni) deve essere determinata dinamicamente in modo da garantire la somministrazione di un target di dose di prescrizione pari a $D_{\text{target}} = 50$ Gy all'apice del tumore. La procedura si articola nei seguenti passaggi:

1. **Identificazione dell'Apice Tumorale:** A partire da una simulazione di riferimento ($\theta = 0^\circ$), l'apice del tumore viene individuato geometricamente come il punto appartenente al volume tumorale situato alla massima distanza dalla superficie della placca ($R_{\text{placca}} + x$), corrispondente a una profondità originale dell'apice reale ≈ 12.8 mm.

2. **Definizione della Regione Apicale (ROI):** Attorno all'apice individuato viene costruita una Region of Interest (ROI) sferica con raggio $R_{\text{sfera}} = 3.5$ mm. Tale dimensione è stata selezionata opportunamente per comprendere circa il 9% dell'intero volume del tumore simulato, fornendo un campione statisticamente rappresentativo della regione apicale.
3. **Traslazione per Ridimensionamento Clinico:** Poiché la geometria del tumore integrata nei modelli di simulazione presenta dimensioni fuori scala (significativamente superiori rispetto ai volumi tumorali oculari trattati comunemente con brachiterapia), il calcolo diretto della dose all'apice originale avrebbe richiesto tempi di erogazione non compatibili con i protocolli clinici standard (2–7 giorni). Per ovviare a questo vincolo tecnico, la regione apicale è stata traslata lungo l'asse verticale di 6.85 mm, posizionando l'apice effettivo a un'altezza clinica di riferimento $h_{\text{apice}} = 6.0$ mm, coerente con le reali dimensioni patologiche (Figura 2.1).
4. **Calcolo del Rateo di Dose Medio sulla ROI Apicale:** Le simulazioni Monte Carlo forniscono la dose assorbita in ogni voxel, normalizzata per singolo evento primario simulato ($D_{\text{evento},v}^{(r)}$, espressa in Gy/evento per il voxel v nel run r). Data l'attività nominale della sorgente $A = 10 \text{ MBq} = 10^7 \text{ Bq}$ (decadimenti/s), il rateo di dose istantaneo del singolo voxel in un dato run è pari a $\dot{D}_v^{(r)} = D_{\text{evento},v}^{(r)} \times A$. Per ottenere un valore unico e statisticamente robusto rappresentativo dell'intera regione apicale, il rateo di dose $\dot{D}_{\text{apice},s}$ (in Gy/s) viene calcolato mediando sia sullo spazio (su tutti gli N_{voxel} appartenenti alla ROI sferica traslata) sia sulle $N_{\text{run}} = 10$ simulazioni indipendenti:

$$\dot{D}_{\text{apice},s} = \frac{1}{N_{\text{run}} \cdot N_{\text{voxel}}} \sum_{r=1}^{N_{\text{run}}} \sum_{v \in \text{ROI}} \left(D_{\text{evento},v}^{(r)} \times A \right) \quad (2.4)$$

5. **Calcolo del Tempo di Trattamento:** Il rateo di dose medio così ottenuto viene convertito su scala giornaliera:

$$\dot{D}_{\text{apice}, \text{giorno}} = \dot{D}_{\text{apice},s} \times 86400 \quad [\text{Gy/giorno}] \quad (2.5)$$

La durata totale del trattamento $T_{\text{trattamento}}$ necessaria per erogare la dose target prescritta $D_{\text{target}} = 50 \text{ Gy}$ è quindi determinata come:

$$T_{\text{trattamento}} = \frac{D_{\text{target}}}{\dot{D}_{\text{apice}, \text{giorno}}} \quad [\text{giorni}] \quad (2.6)$$




Figura 2.1: Rappresentazione 3D del modello oculare voxelizzato e della geometria di traslazione dell'apice. Viene mostrata la posizione dell'apice reale (depth = 12.8 mm) e della relativa ROI sferica da $R = 3.5$ mm (in viola/fucsia), assieme all'apice traslato alla profondità clinica target ($h_{\text{apice}} = 6.0$ mm) con traslazione pari a 6.85 mm. Sono inoltre visibili le strutture anatomiche oculari e la traiettoria delle posizioni della placca ($\theta \in [0^\circ, 355^\circ]$).

Metriche Dosimetriche per Organo e Assemblaggio del Tensore di Output

Per ogni posizione della placca, la dose accumulata durante $T_{\text{trattamento}}$ viene integrata su sei organi e strutture di interesse: Cristallino (ID 1420), Retina (ID 1418), Cornea (ID 1417), Nervo Ottico (ID 2882), Sclera (ID 1415) e Tumore (ID 9999).

Per ciascun organo k , vengono estratte tre metriche statistiche:

- **Dose Media Assorbita ($\bar{D}_k$):** Dose media accumulata sul volume dell'organo, mediata tra i run.
- **Deviazione Standard (σ_k):** Variabilità inter-run della dose media, utile per valutare l'incertezza statistica del metodo Monte Carlo.
- **Dose Massima ($D_{k,\max}$):** Dose assorbita dal voxel più caldo all'interno dell'organo k , fondamentale per verificare il rispetto dei vincoli di dose sugli organi a rischio (OAR) (ad es. Cristallino < 5 Gy, Nervo Ottico < 55 Gy, Retina < 45 Gy).

Il vettore di output $\mathbf{y}_i \in \mathbb{R}^{19}$ per ciascun angolo comprende il tempo di trattamento seguito dalle triplette di feature ($\bar{D}_k, \sigma_k, D_{k,\max}$) ordinate per ID organo:

$$\mathbf{y}_i = [T_{\text{trattamento}}, \bar{D}_{1420}, \sigma_{1420}, D_{1420,\max}, \dots, \bar{D}_{9999}, \sigma_{9999}, D_{9999,\max}] \quad (2.7)$$

Dimensioni Finali dei Dataset

Iterando la procedura per tutte le posizioni angolari discrete ($\theta \in [0^\circ, 355^\circ]$ a passi di 5°), i dati finali sono stati esportati in file binari formato NumPy:

- `input_tensor.npy`: Matrice di dimensioni $(N_{\text{angoli}}, 5)$ contenente le feature geometriche di ingresso.
- `output_tensor.npy`: Matrice di dimensioni $(N_{\text{angoli}}, 19)$ contenente il tempo di trattamento e le metriche dosimetriche di uscita.

3 Strategia Metodologica e Flusso di Lavoro

3.1 Panoramica della Strategia e Flusso di Lavoro

Per superare i pesanti limiti computazionali delle simulazioni Monte Carlo tradizionali eseguite in Geant4, la strategia sviluppata si basa su un approccio in due fasi interconnesse:

1. **Modello Surrogato (Forward Model):** Addestramento di una rete neurale in grado di mappare le feature di ingresso $\mathbf{x}_i \in \mathbb{R}^5$ (funzioni trigonometriche degli angoli e raggio di curvatura/traslazione) nelle metriche dosimetriche e nel tempo di trattamento $\mathbf{y}_i \in \mathbb{R}^{19}$, riducendo i tempi di inferenza a frazioni di secondo rispetto alle simulazioni complete.
2. **Ottimizzazione Differenziabile (Inverse Problem):** Sfruttamento della differenziabilità end-to-end del modello surrogato per identificare la configurazione angolare θ della placca che minimizza una funzione di loss clinica, bilanciando la dose prescritta al tumore e la salvaguardia degli Organi a Rischio (OAR).

3.2 Vincoli Clinici di Dose

L'ottimizzazione del trattamento rispetta i vincoli radiobiologici e le soglie di tolleranza dei tessuti oculari sani, sintetizzati in Tabella 3.1.

Organo / Struttura	OrganID	Soglia di Dose [Gy]	Tipologia di Vincolo
Tumore	9999	> 50.0	Dose Minima Prescritta (D_{target})
Cristallino	1420	< 5.0	Limite Massimo OAR
Retina	1418	< 45.0	Limite Massimo OAR
Cornea	1417	< 50.0	Limite Massimo OAR
Nervo Ottico	2882	< 55.0	Limite Massimo OAR
Sclera	1415	< 100.0	Limite Massimo OAR

Tabella 3.1: Soglie e vincoli clinici di dose per il bersaglio tumorale e gli Organi a Rischio (OAR).

3.3 Approcci Modellistici e Strategie di Splitting del Dataset

Per valutare la robustezza, la capacità di generalizzazione e la stabilità delle stime dosimetriche, il problema è stato affrontato confrontando diverse combinazioni di architetture neurali e strategie di suddivisione (*splitting*) del dataset:

- **MLP Sequenziale con Splitting Random:** Suddivisione casuale delle posizioni angolari tra train e test set per valutare le capacità standard di interpolazione del modello.
- **MLP con Skip Connection e Splitting Deterministico:** Architettura dotata di una connessione residua (per favorire il flusso del gradiente e la stabilità delle derivate durante l'ottimizzazione) combinata con una partizione deterministica delle angolazioni, garantendo riproducibilità e robustezza nei risultati.
- **MLP Sequenziale con Splitting Continuo:** Suddivisione per intervalli angolari continui (con il test set formato da sotto-intervalli angolari contigui) per testare l'estrapolazione e l'accuratezza del modello su regioni dello spazio delle fasi non viste durante l'addestramento.

Validazione Integrata: Ricerca Discreta vs. Ottimizzazione Differenziabile

La strategia di validazione prevede il confronto diretto tra due modalità di ricerca della configurazione ottimale:

1. **Analisi Discreta sullo Spazio Grigliato:** Valutazione della funzione di loss clinica su tutte le posizioni angolari discrete presenti nel dataset ($\theta \in [0^\circ, 355^\circ]$ a passi di 5°).

2. **Raffinamento Continuo tramite Discesa del Gradiente:** Partendo dalle configurazioni discrete più promettenti, si sfrutta la differenziabilità del modello surrogato per eseguire un'ottimizzazione basata su gradiente nello spazio continuo degli angoli.

L'integrazione tra l'analisi discreta e il raffinamento differenziabile permette di verificare se la discesa del gradiente sia in grado di convergere verso minimi locali o globali caratterizzati da una loss clinica inferiore rispetto alla griglia discreta di partenza, garantendo al contempo il rigoroso rispetto dei vincoli sui tessuti sani.

4 Task 1: Creazione e Valutazione dei Modelli Surrogati

4.1 Introduzione

La Task 1 è dedicata alla costruzione e alla valutazione dei modelli surrogati impiegati per riprodurre la risposta dosimetrica delle simulazioni Monte Carlo realizzate in Geant4. Questa fase rappresenta il collegamento tra la preparazione del dataset, descritta nella Sez. 2 e il successivo problema di ottimizzazione del posizionamento della placca per il trattamento (Sez. 5).

Le simulazioni Monte Carlo costituiscono uno strumento accurato per la valutazione della distribuzione di dose all'interno della geometria oculare voxelizzata. Il loro elevato costo computazionale rende tuttavia difficile esplorare rapidamente un numero elevato di possibili configurazioni della placca. Tale limite risulta rilevante quando si vuole individuare una posizione che garantisca contemporaneamente un'adeguata copertura del volume tumorale e una riduzione della dose assorbita dagli Organi a Rischio (OAR).

Per ridurre il costo computazionale è stato quindi introdotto un modello di Deep Learning con funzione di surrogato, addestrato a riprodurre la relazione tra la geometria del trattamento e le corrispondenti quantità dosimetriche. Il modello surrogato deve apprendere la relazione tra le feature geometriche standardizzate e le corrispondenti quantità dosimetriche trasformate:

$$\hat{\mathbf{y}}_i = f_{\text{NN}}(\tilde{\mathbf{x}}_i), \quad f_{\text{NN}} : \mathbb{R}^5 \rightarrow \mathbb{R}^{19}, \quad (4.1)$$

dove $\tilde{\mathbf{x}}_i$ rappresenta il vettore di input standardizzato, mentre $\hat{\mathbf{y}}_i$ è la predizione della rete nello spazio log-trasformato e standardizzato.

La predizione nelle unità fisiche originali viene successivamente ricostruita mediante

$$\hat{y}_j = \exp \left[\text{Scaler}^{-1} \left(\hat{y}_j \right) \right] - 1. \quad (4.2)$$

Mediante l'inversione delle trasformazioni di preprocessing si ottiene quindi il vettore $\hat{\mathbf{y}}_i$ nelle unità fisiche originali, contenente la stima del tempo di trattamento e delle metriche dosimetriche relative al tumore e alle strutture anatomiche considerate.

Oltre a fornire predizioni più rapide rispetto a una nuova simulazione Monte Carlo, il modello deve essere differenziabile rispetto alle variabili geometriche di ingresso. Questa proprietà è necessaria per utilizzare il surrogato come *forward model* all'interno della successiva procedura di ottimizzazione, nella quale la posizione angolare della placca viene modificata mediante tecniche basate sul gradiente.

La costruzione del modello è resa particolarmente complessa dalla dimensione ridotta del dataset. Le simulazioni Monte Carlo comprendono 72 configurazioni della placca, ottenute campionando l'angolo θ nell'intervallo $[0^\circ, 360^\circ)$ con un passo di 5° . Un numero così limitato di campioni non è sufficiente, da solo, a garantire un addestramento stabile di una rete neurale e aumenta sensibilmente il rischio che il modello memorizzi le configurazioni osservate senza apprendere una relazione dosimetrica sufficientemente regolare e generalizzabile.

Per mitigare questo problema è stata quindi introdotta una procedura di *Data Augmentation*, applicata esclusivamente al *Training Set*, con lo scopo di produrre configurazioni leggermente perturbate attorno ai campioni originali e favorire l'apprendimento della dipendenza locale continua tra la posizione della placca e le quantità dosimetriche.

Per studiare il comportamento del modello surrogato in differenti condizioni di addestramento e valutazione, sono state sviluppate tre pipeline distinte. Ciascuna pipeline combina una specifica architettura neurale con una diversa strategia di suddivisione delle 72 configurazioni originali nei set di *Training*, *Validation* e *Test*. Il confronto tra i tre approcci permette di valutare separatamente la capacità di interpolazione del modello, la stabilità rispetto a una distribuzione uniforme dei dati e la capacità di estrapolazione in un settore angolare completamente escluso dall'addestramento.

4.2 Metodologia Generale e Componenti Comuni

Prima di analizzare separatamente i tre modelli, vengono descritte le componenti metodologiche condivise nella Task 1. Le differenti strategie di suddivisione del dataset, le architetture specifiche, le funzioni di loss e gli iperparametri di addestramento saranno invece presentati nelle rispettive sezioni.

Data augmentation angolare

Per aumentare il numero di campioni disponibili durante l'addestramento, ciascun elemento del training set viene affiancato da 29 copie perturbate, ottenendo un fattore complessivo di augmentation pari a $N_{\text{aug}} = 30$ comprensivo del campione originale.

La componente comune della procedura consiste nella perturbazione continua dell'angolo θ . Il valore angolare viene inizialmente ricostruito a partire dalle sue componenti trigonometriche.

A tale valore viene aggiunto un rumore gaussiano:

$$\epsilon_\theta \sim \mathcal{N}(0, \sigma_\theta^2), \quad \sigma_\theta = 1^\circ, \quad (4.3)$$

ottenendo

$$\theta_{\text{aug}} = \theta + \epsilon_\theta. \quad (4.4)$$

Le componenti trigonometriche utilizzate come input vengono quindi ricalcolate come

$$\sin \theta_{\text{aug}}, \quad \cos \theta_{\text{aug}}. \quad (4.5)$$

Per perturbazioni angolari sufficientemente piccole si assume una regolarità locale della risposta dosimetrica. Il vettore target associato al campione originale viene pertanto mantenuto invariato:

$$\mathbf{y}_{\text{aug}} = \mathbf{y}. \quad (4.6)$$

Trasformazione e standardizzazione dei target

Le 19 componenti del target presentano scale numeriche differenti e possono estendersi su più ordini di grandezza. Per ridurre l'asimmetria delle distribuzioni e rendere più stabile il processo di ottimizzazione, viene applicata a ciascuna componente una trasformazione logaritmica:

$$y'_j = \ln(1 + y_j), \quad j = 1, \dots, 19. \quad (4.7)$$

I target trasformati vengono successivamente standardizzati:

$$\tilde{y}_j = \frac{y'_j - \mu_{j,\text{train}}}{\sigma_{j,\text{train}}}, \quad (4.8)$$

dove $\mu_{j,\text{train}}$ e $\sigma_{j,\text{train}}$ rappresentano rispettivamente la media e la deviazione standard della j -esima componente, calcolate utilizzando esclusivamente il training set.

Gli stessi parametri vengono applicati, senza effettuare un nuovo adattamento dello scaler, ai set di validation e test. Questa procedura impedisce che informazioni provenienti dai dati di valutazione influenzino il preprocessing utilizzato durante l'addestramento.

Per riportare una predizione nello spazio fisico originale si applicano, nell'ordine, l'inversa della standardizzazione e l'inversa della trasformazione logaritmica.

Caratteristiche generali dei modelli neurali

I tre modelli sono reti neurali completamente differenziabili che ricevono cinque variabili geometriche in input e restituiscono le 19 componenti del target.

Sebbene le topologie differiscano per numero di neuroni, presenza di connessioni residue e tecniche di normalizzazione, tutte le architetture condividono:

- strati lineari completamente connessi;
- funzioni di attivazione *Gaussian Error Linear Unit* (GELU);
- regolarizzazione mediante Dropout con probabilità $p = 0.15$;
- uno strato finale lineare con 19 unità di output.

La funzione GELU è definita, nella sua forma esatta, come

$$\text{GELU}(x) = x \Phi(x), \quad (4.9)$$

dove $\Phi(x)$ è la funzione di distribuzione cumulativa della distribuzione normale standard.

A differenza della funzione ReLU, la GELU fornisce una trasformazione liscia e differenziabile, favorendo una

variazione più regolare dell'output rispetto agli input. Questa caratteristica risulta particolarmente rilevante in vista dell'impiego del modello surrogato nelle successive procedure di ottimizzazione differenziabile. Durante l'addestramento, il Dropout annulla casualmente una frazione pari al 15% delle attivazioni alle quali viene applicato, riducendo il rischio di adattamento eccessivo ai campioni del training set.

Procedura generale di addestramento

L'addestramento viene effettuato minimizzando una funzione di errore calcolata nello spazio dei target log-trasformati e standardizzati.

In tutti i casi viene utilizzato l'ottimizzatore Adam con regolarizzazione L_2 mediante *weight decay*. Il learning rate viene modificato durante l'addestramento mediante uno scheduler **ReduceLROnPlateau**, sulla base dell'andamento della loss.

Il numero massimo di epoche è fissato a

$$N_{\text{epoch,max}} = 500. \quad (4.10)$$

Durante il training viene memorizzata la configurazione dei parametri associata al valore minimo della validation loss. Al termine dell'addestramento, tale configurazione viene ripristinata e utilizzata per la valutazione sul test set.

Quantificazione dell'incertezza mediante Monte Carlo Dropout

Per ottenere una stima approssimata dell'incertezza epistemica, durante l'inferenza vengono mantenuti attivi i livelli di Dropout, senza eseguire la retropropagazione dei gradienti né aggiornare i parametri della rete.

Per ciascun campione vengono effettuati N_{MC} *forward pass* stocastici:

$$\hat{\mathbf{y}}^{(s)} = f_{\omega}^{(s)}(\mathbf{x}), \quad s = 1, \dots, N_{\text{MC}}, \quad (4.11)$$

dove l'indice s identifica una diversa realizzazione delle maschere di Dropout.

Il numero di campionamenti N_{MC} non è identico per tutti i modelli e viene specificato nelle rispettive sezioni.

Ogni realizzazione viene riportata separatamente nello spazio fisico invertendo la trasformazione logaritmica.

A partire dall'insieme delle predizioni stocastiche è possibile calcolare, per ciascuna componente j , la media empirica

$$\mu_j^{\text{MC}} = \frac{1}{N_{\text{MC}}} \sum_{s=1}^{N_{\text{MC}}} \hat{y}_j^{(s)}, \quad (4.12)$$

e la deviazione standard campionaria

$$\sigma_j^{\text{MC}} = \sqrt{\frac{1}{N_{\text{MC}} - 1} \sum_{s=1}^{N_{\text{MC}}} \left(\hat{y}_j^{(s)} - \mu_j^{\text{MC}} \right)^2}. \quad (4.13)$$

La deviazione standard σ_j^{MC} quantifica la sensibilità della predizione alle differenti realizzazioni stocastiche della rete e viene utilizzata come indicatore approssimato dell'incertezza epistemica del modello.

Tale quantità non deve essere interpretata come un intervallo di confidenza clinico formalmente calibrato e non include l'incertezza statistica associata alle simulazioni Monte Carlo di riferimento.

4.3 Modello 1: MLP Sequenziale con Splitting Random

Il primo approccio analizzato per la costruzione del modello surrogato si basa su un'architettura **MLP (Multi-Layer Perceptron) sequenziale** combinata con un partizionamento di tipo *Random Split*.

Il dataset originale viene suddiviso casualmente con le seguenti proporzioni:

- **Training Set (80%)**: Utilizzato per l'ottimizzazione dei pesi della rete, previa applicazione della procedura di *Data Augmentation* trigonometrica ($\times 30$) descritta nella Sezione 4.2.
- **Validation Set (10%)**: Impiegato per il monitoraggio dell'addestramento e la regolazione dinamica del *learning rate*.
- **Test Set (10%)**: Riservato esclusivamente alla valutazione finale delle prestazioni su dati non visti.

Architettura del Modello e Iperparametri

L'architettura della rete è concepita per garantire una compressione progressiva e una trasformazione non lineare uniforme dello spazio iniziale 5 verso le 19 componenti dosimetriche del target. La topologia del modello è definita come segue:

$$\begin{aligned} \text{Linear}(5, 64) &\rightarrow \text{GELU} \rightarrow \text{Dropout}(0.15) \\ &\rightarrow \text{Linear}(64, 32) \rightarrow \text{GELU} \rightarrow \text{Dropout}(0.15) \\ &\rightarrow \text{Linear}(32, 19) \end{aligned} \quad (4.14)$$

Funzione di Loss Pesata e Processo di Addestramento

L'ottimizzazione della rete è guidata dalla classe `CustomWeightedMSELoss`. I pesi assegnati alle 19 componenti del tensore di output riflettono sia la necessità di compensare il disaccoppiamento delle scale fisiche sia le priorità radioterapiche imposte dal progetto IRIDE.

Per ciascuno dei 6 organi monitorati vengono previste tre quantità fisiche (dose media, deviazione standard spaziale della dose e dose massima), a cui si aggiunge lo scalare relativo al tempo di trattamento. Il vettore dei pesi $\mathbf{w} \in \mathbb{R}^{19}$ è definito come:

$$\mathbf{w} = \left[\underbrace{50.0}_{\text{Tempo}}, \underbrace{10.0, 2.5, 15.0}_{\text{Cristallino } (\mu, \sigma, \max)}, \dots, \underbrace{20.0, 1.5, 15.0}_{\text{Tumore } (\mu, \sigma, \max)} \right] \quad (4.15)$$

L'assegnazione di un grande peso al **Tempo di Trattamento** ($w = 50.0$) assicura un solido ancoraggio per il rateo di dose globale. Contestualmente, l'imposizione di pesi elevati sulle **Dosi Massime degli Organi a Rischio** ($w \in [15.0, 20.0]$) e sulla **Dose Media al Tumore** ($w = 20.0$) vincola il modello ad evitare sottostime clinicamente pericolose nelle regioni critiche e a garantire una corretta copertura del volume bersaglio.

L'ottimizzazione dei parametri è affidata all'algoritmo **Adam** con *learning rate* iniziale $\eta_0 = 10^{-3}$ e termine di *weight decay* $\lambda = 10^{-4}$ per la regolarizzazione dei pesi.

La dinamica dell'apprendimento è controllata dallo scheduler `ReduceLROnPlateau`, che riduce il *learning rate* di un fattore 0.8 qualora la *Validation Loss* non mostri miglioramenti per 50 epoche consecutive, consentendo alla rete di affinare la convergenza nei minimi locali della superficie di loss.

Risultati e Discussione

La valutazione delle prestazioni del primo modello surrogato (MLP Sequenziale con *Random Split*) è stata condotta analizzando sia la dinamica di convergenza durante la fase di addestramento, sia le metriche di errore calcolate nello spazio delle unità fisiche reali (Gy e giorni) mediante la tecnica di *Monte Carlo Dropout* ($N = 100$ campionamenti stocastici).

Dinamica dell'Addestramento e Convergenza

L'andamento della funzione di costo pesata durante le 500 epoche di addestramento è mostrato in Figura 4.1. La curva in scala semilogaritmica evidenzia una convergenza fluida e progressiva della *Training Loss* e della *Validation Loss*.




Figura 4.1: Andamento della *Custom Weighted MSE Loss* durante l'addestramento in scala lineare (sinistra) e semilogaritmica (destra). Il punto rosso evidenzia il miglior modello salvato all'epoca 417 con un valore di loss pari a 0.0399.

L'azione dello scheduler **ReduceLROnPlateau** ha consentito alla rete di superare le fasi di plateau e raggiungere il minimo di validazione all'epoca 417 con un valore di loss pesata pari a $\mathcal{L}_{\text{val}} = 0.0399$. È importante notare che la *Validation Loss* si stabilisce costantemente al di sotto della *Training Loss*: questo comportamento è pienamente giustificato dal fatto che, durante l'addestramento, la rete è soggetta alla *Data Augmentation* stocastica e al *Dropout* attivo (15%), mentre la validazione viene valutata in modalità deterministica sulle configurazioni originali non perturbate.

Valutazione Quantitative sui Dati di Test

Dopo aver ripristinato le predizioni nelle unità fisiche reali tramite de-standardizzazione e inversione della trasformazione logaritmica, sono state calcolate le metriche **MAE** e **MAPE** per ciascuna delle 19 variabili di output, rappresentate graficamente in Figura 4.2.




Figura 4.2: Confronto grafico tra l'Errore Assoluto Medio (MAE, sinistra) e l'Errore Percentuale Assoluto Medio (MAPE, destra) per tutte le componenti predette.

Analisi e Discussione Clinico-Fisica

L'analisi integrata dei grafici e della tabella evidenzia risultati di notevole rilevanza e solidità:

1. **Efficacia sulla Copertura Terapeutica e sul Tempo:** Il modello dimostra un'elevata accuratezza nella stima del **Tempo di Trattamento** (MAPE = 4.33%, MAE $\approx$ 34.0 giorni) e della dose al **Tumore**, con un MAPE contenuto all' 8.03% per la dose media e al 9.38% per la dose massima. Ciò conferma la capacità della rete di preservare l'affidabilità clinica nella valutazione della copertura radioterapeutica del volume bersaglio.
2. **Dosi Medie agli Organi a Rischio (OAR):** Per tutte le strutture critiche (Retina, Sclera, Cristallino, Cornea, Nervo Ottico), l'errore percentuale medio (MAPE) sulle dosi medie si mantiene stabilmente al di sotto del 10% (4.43% per la Retina, 4.76% per la Sclera, 6.00% per la Cornea, 7.53% per il Cristallino e 9.37% per il Nervo Ottico).
3. **Interpretazione dei Gradienti Elevati e della Scala Temporale:** L'analisi dell'errore assoluto (MAE, Figura 4.2, sinistra) mostra valori elevati in termini di Gy per le dosi massime di Sclera (MAE $\approx$ 10.1 kGy) e Retina (MAE $\approx$ 10.1 kGy). Tali ampiezze numeriche trovano una diretta spiegazione fisica nell'ampio intervallo dei tempi di esposizione considerati nel dataset (variabili da 6 fino a oltre 2000 giorni a seconda della configurazione della placca), che integrano dosi accumulate estremamente elevate nelle zone a diretto contatto con la sorgente (legge dell'inverso del quadrato della distanza, $1/r^2$). Nonostante l'elevata scala dei valori assoluti, l'efficacia dell'addestramento e della trasformazione logaritmica $\ln(1+y)$ consente di contenere l'errore relativo (MAPE, Figura 4.2, destra) a valori del 5.66% per la Sclera e dell' 11.78% per la Retina.
4. **Deviazioni Standard Spaziali:** Le deviazioni standard della dose all'interno degli organi presentano valori di MAPE più elevati (fino al 54.40% per il Cristallino). Questo comportamento è fisiologico e legato alla ridotta ampiezza assoluta di tali quantità (valori nell'ordine di 1 – 36 Gy), per le quali piccole fluttuazioni predittive si ripercuotono in variazioni percentuali rilevanti, senza inficiare la bontà complessiva della ricostruzione dosimetrica.

Campionamento Stocastico e Incertezza con MC Dropout

Per valutare la bontà delle predizioni puntuali rispetto ai valori reali simulati Monte Carlo, le Figure 4.3, 4.4 e 4.5 riportano i diagrammi di dispersione (*scatter plot*) con le relative barre d'errore corrispondenti all'incertezza σ estrapolata dai 100 passaggi di MC Dropout.




Figura 4.3: Scatter plot del Tempo di Trattamento predetto rispetto al valore simulato Monte Carlo. La linea tratteggiata rossa indica la predizione ideale ($y = x$). Le barre d'errore verdi rappresentano l'incertezza σ calcolata tramite MC Dropout.




Figura 4.4: Scatter plot per le Dosi Medie dei 6 organi anatomici. I punti blu rappresentano i campioni di test, mentre le barre d'errore evidenziano la deviazione standard empirica tra i 100 passaggi stocastici di inferenza.




Figura 4.5: Scatter plot per le Dosi Massime dei 6 organi anatomici. Si noti come la distribuzione dei dati si allinei coerentemente lungo l'asse della perfetta corrispondenza $y = x$ su diversi ordini di grandezza.

I grafici confermano un'ottima aderenza dei punti alla retta dell'ideale corrispondenza $y = x$. Inoltre, l'ampiezza delle barre d'errore σ ricavate dal MC Dropout risulta proporzionale allo scostamento dal valore reale: le predizioni con maggiore deviazione (es. per valori elevati di dose massima sul Nervo Ottico o sulla Sclera) presentano una barra di incertezza più estesa.

Ciò dimostra che il metodo **MC Dropout** costituisce uno strumento efficace di autovalutazione per la rete, fornendo al fisico medico un chiaro indicatore sulla confidenza della predizione per ogni specifica geometria oculare.

4.4 Modello 2: MLP con Skip Connection e Splitting Sistemico

Per superare i limiti espressivi di un'architettura puramente sequenziale e catturare al meglio i complessi gradienti dosimetrici, è stato sviluppato un modello MLP arricchito con una Skip Connection. Questa integrazione agevola la propagazione del gradiente e focalizza l'apprendimento dei layer nascosti sulle correzioni non lineari, che costituiscono la componente residua del modello.

Partizionamento sistematico dei dati

Per garantire una valutazione più rigorosa e spazialmente uniforme si è optato per uno splitting deterministico basato sull'uso dell'operatore modulo. Il dataset è stato diviso in blocchi ripetitivi di 10 elementi: i primi 8 costituiscono il *Training Set*, il nono e il decimo formano rispettivamente il *Validation Set* e il *Test Set*. Questa strategia mantiene una proporzione 80/10/10, ma garantisce una maggiore omogeneità, assicurando che la rete disponga di dati di addestramento locali in qualsiasi settore angolare.

Ottimizzazione degli Iperparametri con Optuna

Al fine di escludere bias soggettivi nella definizione dei pesi per la funzione di costo personalizzata (`CustomWeightedMSELoss`) e del learning rate per l'ottimizzatore `Adam`, la sintonizzazione degli iperparametri è stata affidata al framework `Optuna` tramite una ricerca nello spazio delle configurazioni.

L'obiettivo imposto ad `Optuna` (`objective`) è stato la minimizzazione dell'errore di generalizzazione della rete. Lo spazio di ricerca è stato definito tenendo conto delle priorità cliniche:

- **Tempo di trattamento:** Intervallo esplorato compreso tra 5.0 e 30.0.
- **Dosi medie e Dosi massime:** I pesi sono stati disaccoppiati e ottimizzati indipendentemente per ciascun organo. Agli organi non critici è stato assegnato un range compreso tra 0.5 e 10.0, mentre per gli organi a rischio (OAR) il range è stato innalzato per spaziare tra 2.0 e 20.0.

- **Deviazioni standard:** Non essendo un parametro primario per la valutazione clinica, il relativo peso è stato vincolato a una frazione del peso assegnato alla dose media del rispettivo organo, con un rapporto variabile tra 0.1 e 0.5.
- **Learning rate:** Viene posto un range $[10^{-5}, 10^{-2}]$.

Un aspetto metodologico cruciale ha riguardato la metrica di valutazione restituita a Optuna. Sebbene la backpropagation nel ciclo di training sia guidata dalla funzione di costo pesata, valutare i singoli trial sulla base della medesima loss avrebbe spinto l'ottimizzatore verso configurazioni con pesi tendenti a zero. Per prevenire questa anomalia, le prestazioni sul Validation Set sono state misurate utilizzando un MSE standard non pesato. In questo modo si forza il framework a premiare le combinazioni di iperparametri che minimizzano l'errore assoluto reale.

Per massimizzare l'efficienza computazionale, sono stati integrati tre meccanismi di controllo:

1. **Early Stopping:** Interrompe l'addestramento se la metrica di validazione reale non migliora per 20 epoche consecutive e ripristina i pesi ottimali.
2. **Learning Rate Scheduler:** Dimezza il learning rate in maniera dinamica se l'addestramento entra in fase di plateau (*patience* = 7).
3. **Pruning:** Analizza l'andamento della *Validation Loss* durante le prime epoche di un *trial*. Se le performance sono inferiori rispetto ad un target (nel caso del **MedianPruner** si utilizza la mediana), l'addestramento viene abortito prematuramente.

Architettura del modello

Il modello elabora tensori di ingresso a 5 dimensioni e restituisce predizioni a 19 dimensioni. La topologia si articola nei seguenti moduli:

- **Input Layer:** Un layer di proiezione iniziale completamente connesso che espande le 5 feature di ingresso in uno spazio a 128 neuroni.
- **Attivazione GELU:** Le *Gaussian Error Linear Unit* garantiscono una non-linearità più liscia prevenendo il problema dei "neuroni morti", migliorando la convergenza.
- **Skip Connection:** L'output del layer di ingresso (x_{hidden}) viene salvato come *tensore residuo*. Successivamente, l'informazione attraversa un blocco costituito da due layer da 128 neuroni intervallati da un'attivazione GELU. Prima di passare nel blocco finale, il percorso si ricongiunge sommando l'output originale e quello elaborato.
- **Regolarizzazione:** Viene impostato un layer di *Dropout* con una probabilità di disattivazione dei neuroni del 15%; questa strategia permette di minimizzare la possibilità che il modello impari a memoria poiché spegnendo casualmente il 15% dei neuroni ad ogni epoca di addestramento il modello che analizzerà i dati sarà leggermente diverso, questo costringe il modello stesso a non imparare mnemonicamente.
- **Output Layer:** Un layer finale comprime lo spazio passando da 128 neuroni a 19 (numero totale delle componenti fisiche richieste).

L'architettura è schematicamente rappresentata in Fig. 4.6.




Figura 4.6: Flusso informativo nell'architettura MLP con Skip Connection e blocco residuo.

batch_size ed Early Stopping

Grazie alla *Data Augmentation* è stato possibile, al fine di migliorare la stabilità nel calcolo dei gradienti, aumentare il **batch_size** a 128 in modo che in ogni epoca di allenamento i gradienti vengano ricalcolati solo 13 volte. Infine, viene introdotto di nuovo un sistema di controllo basato sull'early stopping in modo da avere maggior controllo sulla fase di addestramento e terminare il ciclo di addestramento se, avanzando nelle epoche, non si ottengono miglioramenti significativi (in questo caso si ha una **patience** = 20).

Risultati e Discussione

L'addestramento del modello MLP con architettura residua e partizionamento deterministico dei dati ha mostrato un'eccellente stabilità e un'elevata capacità di generalizzazione. Come illustrato nelle curve di apprendimento (Fig. 4.7), il processo di minimizzazione della funzione di costo converge rapidamente, stabilizzandosi su un valore di $MSE \sim 0.03$. Inoltre, la presenza del *Dropout* ha garantito un'efficace regolarizzazione come si può vedere dall'andamento della loss di validazione che rimane costantemente allineata a quella di training.




Figura 4.7: Andamento della Custom Weighted MSE Loss durante l'addestramento in scala lineare (sinistra) e semilogaritmica (destra). La stabilità si raggiunge attorno all'epoca 15 mentre l'early stopping interviene intorno all'epoca 72.

La Fig. 4.8 riassume le metriche di errore su ciascun parametro determinato dalla rete. In particolare, la valutazione quantitativa sul *Test Set* evidenzia un **MAPE medio globale del 14.84%**. L'errore percentuale si concentra principalmente sulle deviazioni standard, coerentemente con il minor peso assegnato da *Optuna*. Al contrario si ha una buona precisione sulle grandezze cliniche primarie: $MAPE_{\bar{D}} < 9\%$, $MAPE_{D_{MAX}}$ tra **6.41%** (Nervo Ottico) e **15.47%** (Sclera) e $MAPE_{T_{tratt}} = 8.75\%$.




Figura 4.8: Grafico a barre riassuntivo dell'errore sui parametri predetti dal modello. Si evidenzia una buona stabilità sui parametri di primo interesse clinico mentre si ha un'errore più marcato nelle deviazioni standard a causa dei pesi minori assegnati da *Optuna*, come era previsto.

Per integrare l'analisi metrica, la bontà di fit del modello surrogato è stata valutata graficamente confrontando i valori reali simulati con le predizioni della rete sul *Test Set*. Come evidenziato dai relativi *scatter plot* (Fig. 4.9, 4.10, 4.11), i punti si allineano con elevata precisione lungo la bisettrice ideale ($y = x$), dimostrando l'assenza di bias sistematici di sovrastima o sottostima. Nello specifico: sul T_{tratt} il modello apprende la dipendenza funzionale con il settore angolare, registrando scarti minimi sull'intero dominio temporale, per la $\bar{D}_{media}$

si registra un'eccellente concordanza in tutti i distretti anatomici e per $\bar{D}_{max}$ la rete modella accuratamente i picchi di dose anche in presenza di forti gradienti. Le barre d'errore mostrano un'ampiezza fisiologicamente proporzionale alla dose, risultando più marcate solo nelle regioni a diretto contatto con la placca brachiterapica.




Figura 4.9: Prestazioni di predizione sulla dose media: si registra un'eccellenza nella predizione della dose media rilasciata nel tumore confermando la massima affidabilità del modello sul bersaglio primario. Il modello predice bene anche negli OAR dove la rete mantiene una buona linearità.




Figura 4.10: Prestazioni di predizione sulla dose massima: la rete non mostra fenomeni di saturazione o deviazioni sistematiche e le barre di incertezza maggiori sugli organi più a contatto alla sorgente sono dovute alla posizione geometrica di tali strutture.




Figura 4.11: Prestazioni di predizione sul tempo di trattamento: l'allineamento con la bisettrice è buono su tutta la scala temporale, tuttavia si nota una lieve sovrastima nel settore angolare 145° . Questo non rappresenta un problema drammatico poiché il tempo di trattamento in questo caso risulta incompatibile con i vincoli clinici.

4.5 Modello 3: MLP Sequenziale con Split Angolare Continuo

Definizione dello Split Angolare Out-Of-Distribution

A differenza degli splitting che valutano il modello in interpolazione, questo approccio è uno *stress test* di estrapolazione *Leave-Sector-Out*: non punta a massimizzare l'accuratezza, ma a osservare il comportamento del surrogato quando un intero settore angolare clinicamente rilevante è escluso sia dall'addestramento sia dalla *model selection*.

Il tumore è centrato in $\theta_{\text{tumore}} = 0^\circ$ e il settore angolare

$$d_{\text{circ}}(\theta, 0) \leq 45^\circ, \quad d_{\text{circ}}(\theta, 0) = \min(\theta_{\text{mod}}, 360^\circ - \theta_{\text{mod}}), \quad (4.16)$$

con $\theta_{\text{mod}} = \theta \bmod 360^\circ$, viene escluso sia dal training sia dalla model selection e riservato interamente al test set, come si vede in tabella 4.1.

Sottoinsieme	N. Config.	Dominio Angolare (θ)
Training Set	42	Settore lontano dal tumore ($d_{\text{circ}} > 45^\circ$)
Validation Set	11	Interlacciato nel settore di Training (una ogni 5)
Test Set	19	Settore <i>near-tumor</i> ($d_{\text{circ}} \leq 45^\circ$)

Tabella 4.1: Suddivisione del dataset nello split angolare continuo.

Il Validation Set è estratto esclusivamente dal settore lontano dal tumore, selezionando in modo deterministico una configurazione ogni cinque dopo l'ordinamento rispetto a θ . Poiché le configurazioni di Validation sono connesse con quelle di Training e distano 5° dalla configurazione di Training più vicina, questo sottoinsieme valuta la capacità di interpolazione locale del modello. Non fornisce invece informazioni sulla capacità di estrapolazione nel settore escluso, che viene valutata esclusivamente sul Test Set.

Funzione di Loss e Processo di Addestramento

I target sono trasformati mediante $\log_{1p}$ e standardizzati separatamente,

$$\tilde{y}_j = \frac{\log(1 + y_j) - \mu_j}{\sigma_j}, \quad (4.17)$$

dove μ_j e σ_j sono calcolati esclusivamente sul Training Set per ciascun output. La trasformazione logaritmica riduce la dinamica e l'asimmetria delle distribuzioni, mentre la standardizzazione porta gli output su scale confrontabili, evitando che le quantità numericamente più elevate dominino l'ottimizzazione. Per un mini-batch

di B campioni, la funzione di costo è una Mean Squared Error pesata:

$$\mathcal{L} = \frac{1}{B} \sum_{b=1}^B \frac{\sum_{j=1}^{N_{\text{output}}} w_j \left(\widehat{y}_{b,j} - \widetilde{y}_{b,j} \right)^2}{\sum_{j=1}^{N_{\text{output}}} w_j}, \quad N_{\text{output}} = 19. \quad (4.18)$$

La normalizzazione rispetto alla somma dei pesi rende la loss invariante rispetto a una moltiplicazione comune di tutti i coefficienti.

Scelta dei pesi uniformi. A differenza del modello con *Random Split*, che adotta pesi differenziati per riflettere le priorità radioterapeutiche, questo modello impiega **pesi uniformi** $w_j = 1$, $j = 1, \dots, 19$. La loss coincide pertanto con la Mean Squared Error calcolata sui target log-standardizzati. Questa scelta evita di introdurre una ponderazione differenziata tra gli output nella valutazione dello split angolare. Poiché il Training Set e il Validation Set appartengono entrambi al settore lontano dal tumore, eventuali pesi selezionati sulla *validation* rifletterebbero esclusivamente il dominio angolare osservato, senza garanzia di validità nel settore *near-tumor* riservato al test.

Processo di addestramento. L'ottimizzazione impiega l'algoritmo **Adam** con *learning rate* iniziale $\eta_0 = 10^{-3}$ e *weight decay* $\lambda = 10^{-4}$. La dinamica è controllata dallo scheduler **ReduceLRonPlateau**, che riduce il *learning rate* di un fattore 0.5 quando la *Validation Loss* non migliora per 25 epoche consecutive, fino a un valore minimo $\eta_{\min} = 10^{-6}$. Un criterio di *early stopping* con *patience* 60 interrompe l'addestramento entro un limite massimo di 500 epoche e ripristina i parametri corrispondenti al minimo della *Validation Loss*. La **Data Augmentation** ($\times 30$, $\sigma_\theta = 1^\circ$) è applicata esclusivamente al Training Set, con *batch size* pari a 16.

Risultati e Discussione

La valutazione delle prestazioni è stata condotta interamente nello spazio delle unità fisiche (Gy e giorni). L'incertezza epistemica è stata stimata tramite *Monte Carlo Dropout*, eseguendo $N = 500$ *forward pass* stocastici per ciascuna configurazione, dai quali si ricavano la predizione centrale e la dispersione σ_{MC} .

Poiché la trasformazione inversa expm1 è convessa, i possibili stimatori della predizione centrale (media e mediana nello spazio fisico, media nello spazio logaritmico, predizione deterministica) non coincidono. Lo stimatore è stato selezionato sul Validation Set, minimizzando l'errore assoluto medio normalizzato alla scala di ciascun output, e successivamente mantenuto fisso nella valutazione sul Test Set, in modo da non introdurre alcuna informazione proveniente dal settore escluso.

Tutte le metriche e i grafici riportati di seguito si riferiscono al Test Set OOD, cioè al settore *near-tumor* $|\theta| \leq 45^\circ$ mai osservato durante l'addestramento.

Dinamica dell'Addestramento e Convergenza

L'andamento della funzione di costo durante l'addestramento è mostrato in Figura 4.12. In scala semilogaritmica, la *Training Loss* e la *Validation Loss* decrescono rapidamente nelle prime epoche, per poi raggiungere una regione di plateau. L'azione dello scheduler **ReduceLRonPlateau** interviene ripetutamente nel corso dell'ottimizzazione, consentendo alla rete di superare le fasi di stallo; il minimo della *Validation Loss* è raggiunto all'epoca 309 con $\mathcal{L}_{\text{val},\min} = 0.0170$, su un totale di 369 epoche prima dell'*early stopping*.




Figura 4.12: Andamento della loss nello spazio log-standardizzato durante l’addestramento, in scala lineare (sinistra) e semilogaritmica (destra). Il punto evidenzia il modello migliore, salvato all’epoca 309 con $\mathcal{L}_{\text{val}} = 0.0170$.

Rapporto tra le due loss. La *Training Loss* si mantiene sistematicamente superiore alla *Validation Loss* (rapporto finale ≈ 1.98). Questo comportamento non indica un’anomalia, poiché le due loss sono calcolate in condizioni differenti: durante il training il dropout è attivo e la rete è valutata anche sui campioni perturbati dalla data augmentation, mentre la validazione è eseguita in modalità deterministica sui campioni originali. Il compito di validazione risulta quindi meno rumoroso di quello usato per aggiornare i parametri. Non si osserva la divergenza progressiva tipica dell’*overfitting*, in cui la *Training Loss* continua a diminuire mentre la *Validation Loss* risale.

Limiti dell’interpretazione. Training e Validation Set appartengono al medesimo dominio angolare, dal quale è escluso il settore *near-tumor*. Le *learning curves* misurano pertanto la sola generalizzazione *in-domain*, cioè l’interpolazione tra configurazioni adiacenti nella griglia angolare, e non forniscono alcuna informazione sulla capacità di estrapolazione nel settore riservato al test. La regolarità delle curve è quindi pienamente compatibile con il netto peggioramento delle prestazioni osservato sul Test Set: una convergenza pulita e priva di *overfitting* non costituisce, da sola, evidenza di affidabilità del surrogato nella regione clinicamente rilevante.

Valutazione Quantitativa sui Dati di Test

Ripristinate le predizioni nelle unità fisiche, le prestazioni sul Test Set sono state quantificate tramite l’errore assoluto medio **MAE** e l’errore percentuale medio **MAPE**.

Il confronto tra le due metriche (Figura 4.13) è esso stesso informativo, poiché produce due ordinamenti distinti degli output.

In termini di **errore assoluto**, i valori più elevati riguardano le dosi massime di sclera, retina e cornea. Questa graduatoria riflette tuttavia la sola scala numerica delle grandezze: la sclera assorbe dosi dell’ordine delle migliaia di Gy, per cui anche un errore relativamente modesto si traduce in un **MAE** elevato. Considerato isolatamente, il **MAE** non distingue quindi la difficoltà predittiva dalla semplice ampiezza del target.

L’**errore percentuale** riordina le priorità. I valori massimi si spostano su cornea e nervo ottico (fino al 261%), cioè sulle strutture che nel settore *near-tumor* ricevono le dosi più basse: quando la placca è affacciata sul tumore, queste strutture sono efficacemente protette, e il modello — addestrato in configurazioni in cui ricevono dosi molto maggiori — non ricostruisce tale riduzione, producendo scarti percentuali ampi. La sclera, dominante in scala assoluta, rientra invece su valori intermedi ($\sim 100\%$).

Il contrasto conferma la natura del fallimento in estrapolazione: la sovrastima è massima, in termini relativi, dove la dose reale è minima. Fa eccezione il tumore, che presenta i **MAPE** più bassi dell’intero insieme sia sulla dose media (13.45%) sia sulla dose massima (16.04%): la sua dipendenza angolare, più regolare, è l’unica che il modello estrapola in modo quantitativamente accettabile.

Estimatori per l’Analisi in Regime di Estrapolazione

Trattandosi di un modello volutamente in estrapolazione, l’analisi richiede indicatori che ne caratterizzino la struttura dell’errore oltre alla sola ampiezza: il bias, il coefficiente di determinazione R^2 , la dispersione di Monte Carlo Dropout σ_{MC} e la copertura dell’intervallo predittivo al 5–95%.

Il bias è quasi ovunque positivo e prossimo in modulo al **MAE**: la sovrastima è quindi sistematica e riguarda tutte le configurazioni del test. I valori di R^2 sono prevalentemente negativi, indicando prestazioni inferiori a quelle di un predittore costante pari alla media del test; il risultato è atteso in estrapolazione e amplificato dalla ridotta variabilità del target nel settore *near-tumor*. Fanno eccezione la dose media al nervo ottico e al




Figura 4.13: Errore assoluto medio (sinistra) ed errore percentuale medio (destra) per ciascuno dei 19 output, sul Test Set OOD. I due ordinamenti differiscono: il MAE riflette la scala numerica delle grandezze, mentre il MAPE evidenzia le strutture peggio ricostruite in termini relativi.

Feature (Dose Media)	Bias	R^2	σ_{MC}	Cop. 5–95%
Cristallino	+0.267	+0.041	1.03	100.0%
Retina	+34.16	−3.072	47.45	47.4%
Cornea	+6.81	−1.072	9.55	63.2%
Nervo Ottico	+32.86	+0.223	54.28	57.9%
Sclera	+70.86	−2.470	93.09	52.6%
Tumore	−4.41	−1.216	7.28	100.0%
Tempo (giorni)	+2.23	−1.919	5.82	100.0%

Tabella 4.2: Bias, coefficiente di determinazione, dispersione MC Dropout media e copertura empirica dell’intervallo 5–95% sul Test Set OOD.

cristallino, con R^2 positivo. La dose media al tumore, unica, è *sottostimata* (Bias < 0).

L’incertezza di Monte Carlo Dropout non identifica correttamente il regime di estrapolazione: la copertura si discosta dal valore nominale del 90% in entrambe le direzioni, risultando eccessiva per gli output a dispersione elevata (100%) e insufficiente per retina e sclera (< 55%). La dispersione MC misura quindi la variabilità interna del modello, ma non fornisce una stima calibrata dell’errore commesso.

Campionamento Stocastico, incertezza con MC Dropout

Le predizioni centrali sono confrontate con i valori Geant4 del Test Set negli scatter plot delle Figure 4.14, 4.15 e 4.16. Ogni punto rappresenta una configurazione del settore *near-tumor*; la diagonale $\hat{y} = y$ corrisponde alla predizione ideale, per cui i punti al di sopra indicano sovrastime e quelli al di sotto sottostime. All’interno di ciascun pannello gli assi condividono limiti e scala, così che la distanza dalla diagonale sia direttamente confrontabile.

Dose media. Per la maggior parte degli organi a rischio i punti si collocano al di sopra della diagonale, indicando una sovrastima della dose media. Dove **MAE** e bias positivo coincidono, tutte le configurazioni presentano errori dello stesso segno. Il nervo ottico costituisce un’eccezione parziale: la differenza tra MAE e bias mostra che non tutte le configurazioni sono sovrastimate, e il suo R^2 positivo (+0.223) indica che parte della variazione tra configurazioni è riprodotta. La dose media al tumore presenta invece un bias negativo, ovvero una sottostima; il relativo errore percentuale è contenuto, ma l’ R^2 negativo indica che la variazione tra configurazioni non è ricostruita.

Predizione della dose media (predizione centrale: deterministica)




Figura 4.14: Predizione della dose media ai sei organi rispetto ai valori Geant4, Test Set.

Dose massima. Anche per la dose massima prevale la sovrastima. La struttura si conferma per il nervo ottico ($R^2 = +0.328$) e, in modo netto, per il tumore, che presenta il coefficiente più elevato dell'intera analisi ($R^2 = +0.711$): per questa quantità il modello segue approssimativamente la diagonale, pur mantenendo un bias positivo. Le restanti strutture mostrano R^2 negativi, con i valori peggiori su retina e sclera.

Predizione della dose massima (predizione centrale: deterministica)




Figura 4.15: Predizione della dose massima ai sei organi rispetto ai valori Geant4, Test Set OOD.

Tempo di irradiazione. Tutti i punti del Test Set si collocano al di sopra della diagonale: la sovrastima del tempo è quindi sistematica, confermata dalla vicinanza tra bias e MAE. Il RMSE è solo lievemente superiore

al MAE, segno che gli errori hanno ampiezze omogenee e non sono dominati da poche configurazioni anomale. Il coefficiente $R^2 = -1.919$: nel settore escluso la somma degli errori quadratici supera quella di un predittore costante pari alla media dei tempi del test, risultato influenzato sia dalla sovrastima sistematica sia dalla ridotta variabilità dei tempi Geant4 in questa regione ($\sigma_t = 1.36$ giorni). La distinzione dei punti per segno di θ (Figura 4.16, destra) evidenzia due sequenze associate ai lati opposti della direzione tumorale: per il tempo il modello riproduce correttamente questa organizzazione angolare, con asimmetria predetta concorde in segno a quella Geant4, sebbene leggermente attenuata.




Figura 4.16: Predizione del tempo di irradiazione rispetto ai valori Geant4, Test Set OOD. A sinistra la vista standard, a destra la separazione dei punti per segno di θ , che evidenzia i due rami corrispondenti ai lati opposti della direzione tumorale.

In sintesi, nel settore escluso dal training il modello conserva l'ordine di grandezza e, per alcune quantità (tempo, dose massima al tumore e al nervo ottico), la dipendenza dall'angolo, ma non riproduce il livello assoluto del target. Le predizioni sono quindi utili a uno studio qualitativo dell'andamento angolare del surrogato, non come stima quantitativa.

5 Pianificazione Inversa, Ottimizzazione Geometrica e Valutazione di Robustezza

La Task 2 e la Task 3 rappresentano il cuore dell'applicazione clinica del progetto IRIDE. In questa fase si richiede di utilizzare i modelli sviluppati (Sez. 4) per ottimizzare il posizionamento della placca. In particolare, i modelli opportunamente addestrati devono fornire indicazioni sulla configurazione ottimale per garantire il rispetto dei vincoli clinici imposti (Sez. 3).

5.1 Task 2: Ottimizzazione del Posizionamento della Placca (Discreta e Differenziabile)

Nella task 2 la funzione obiettivo globale da minimizzare è stata scelta come la somma delle dosi massime stimate su tutti gli OAR:

$$\mathcal{L}_{\text{obj}} = \sum_{\text{organi}} D_{\text{max, pesata}} \quad (5.1)$$

Per la risoluzione del problema sono proposti due differenti approcci.

Esplorazione discreta e filtraggio booleano

Il primo approccio implementato adotta un campionamento sistematico dello spazio angolare $\theta \in [0^\circ, 360^\circ)$ con un passo discreto $\Delta\theta = 5^\circ$. La pipeline con cui si giunge al risultato segue la seguente strategia: il vettore di ingresso è costruito impostando il raggio medio calcolato nel dataset mantenendo l'angolo polare nullo, le 72 configurazioni a disposizione sono inviate al modello surrogato per ottenere le stime dosimetriche e infine con una maschera booleana vengono filtrate le configurazioni che violano almeno uno dei vincoli mentre le configurazioni che superano il filtraggio vengono ordinate in base alla metrica $\mathcal{L}_{\text{obj}}$.

Ottimizzazione continua differenziabile

Uno dei punti di forza dell'esplorazione discreta è la sua rapidità di esecuzione, tuttavia, il passo discreto della griglia causa delle perdite nell'accuratezza. Per questa ragione cruciale risulta molto importante sviluppare una tecnica di ottimizzazione differenziabile. In questo caso la strategia prevede di elevare l'angolo θ a unico parametro addestrabile del sistema mentre i pesi della rete vengono volutamente congelati. Per consentire l'ottimizzazione tramite la tecnica **Gradient Descent** i vincoli clinici vengono convertiti in penalità $\mathcal{P}_k(\theta)$ tramite l'operatore ReLU (attivate solo in caso di superamento della soglia). La funzione di perdita diventa dunque:

$$\mathcal{L}_{\text{tot}}(\theta) = \mathcal{L}_{\text{obj}}(\theta) + \lambda \sum_k \mathcal{P}_k(\theta) \quad (5.2)$$

dove $\lambda = 1000.0$ è un parametro impostato per penalizzare drasticamente i possibili sconfinamenti e k rappresenta la metrica k -esima. Data la non-linearità della mappa dosimetrica attorno all'occhio $\mathcal{L}_{\text{tot}}(\theta)$ presenta diversi minimi locali. Al fine di evitare l'intrappolamento della rete in una soluzione sub-ottimale l'ottimizzazione è fatta in parallelo a partire da 4 configurazioni uniformemente distanziate nei quattro quadranti ($0^\circ, 90^\circ, 180^\circ, 270^\circ$), garantendo la convergenza verso il minimo globale.

5.2 Task 3

La task 2 fornisce una stima puntuale della configurazione angolare ottimale, tuttavia dal punto di vista clinico diventa fondamentale stimare la stabilità della configurazione in termini di incertezza intrinseca del modello. Nell'ultima fase del progetto viene implementato un algoritmo di valutazione dell'intervallo di confidenza proprio per sopperire a tale necessità.

Valutazione della robustezza discreta con Monte Carlo Dropout

Nel primo approccio di analisi statistica lo spazio di ricerca discreto, formato dalle 72 configurazioni disponibili, viene valutato $N = 1000$ volte. In ciascuna iterazione, il *Dropout* disattiva casualmente una frazione dei neuroni permettendo l'analisi da parte di insiemi di neuroni diversi volta per volta e l'algoritmo di estrazione della miglior configurazione sviluppato per la task 2 viene usato per lo stesso scopo. Al termine delle iterazioni si calcola la **frequenza di vittoria** che rappresenta il **livello di confidenza stocastico**. Questa procedura permette di ottenere un'elevata indipendenza del risultato dalla particolare configurazione neurale utilizzata per la valutazione.

Monte Carlo Dropout differenziabile

Per propagare il concetto di robustezza nel dominio continuo è stato combinato l'algoritmo di ottimizzazione differenziabile discusso per la task 2 con una strategia iterativa. Infatti, sono state eseguite $N = 10000$ ottimizzazioni indipendenti tramite **Discesa del Gradiente** mantenendo il *Dropout* attivo.

Al fine di evitare la creazione di artefatti dovuti alla topologia del dominio fisico (che presenta una discontinuità proprio nella regione della configurazione ottimale), si è scelto di rimappare i valori di output con $\theta > 180^\circ$ nel corrispondente valore angolare negativo.

Al termine delle iterazioni, si ottengono l'**angolo ottimale medio** μ_{θ^*} e l'**incertezza angolare** σ_{θ^*} che permettono di rappresentare la distribuzione di probabilità delle configurazioni e di stabilire la **zona di tolleranza probabilistica**. Tale regione rappresenta la porzione di superficie oculare entro cui si può posizionare la placca senza il rischio di violare i limiti radiobiologici.

5.3 Risultati del MLP Sequenziale con Splitting Random

Task 2a: Ricerca Discreta ed Esplorazione dei Vincoli Clinici

L'esplorazione sistematica della griglia discreta con passo $\Delta\theta = 5^\circ$ (72 configurazioni angolari) ha permesso di applicare il filtro booleano basato sui vincoli di radioprotezione definiti per gli Organi a Rischio (OAR).

Dei 72 nodi angolari analizzati, **9 configurazioni hanno superato tutti i limiti clinici** senza alcuna violazione (con riferimento ai limiti riportati nella Tabella 3.1).

La configurazione ottimale sul grigliato discreto è individuata esattamente a $\theta^* = 0^\circ$, con un tempo di trattamento predetto pari a **6.46 giorni** e un valore dello *Score Max OAR* (somma delle dosi massime sugli OAR) pari a **10.93**. Le dosi medie predette nei tessuti sani risultano ampiamente inferiori alle rispettive soglie di tolleranza clinica:

- **Cristallino:** 0.48 Gy (Soglia: 5.0 Gy)
- **Retina:** 28.54 Gy (Soglia: 45.0 Gy)
- **Cornea:** 2.12 Gy (Soglia: 50.0 Gy)
- **Nervo Ottico:** 7.32 Gy (Soglia: 55.0 Gy)
- **Sclera:** 47.49 Gy (Soglia: 100.0 Gy)

Task 2b: Raffinamento mediante Ottimizzazione Continua Differenziabile

I risultati dei quattro percorsi di ottimizzazione indipendenti sono riassunti di seguito:

- **Start 0° :** $\theta \rightarrow 359.79^\circ$ ($\mathcal{L}_{\text{tot}} = 10.9304$)
- **Start 90° :** $\theta \rightarrow 55.22^\circ$ ($\mathcal{L}_{\text{tot}} = 4.92 \times 10^7$ – penalità per violazione vincoli)
- **Start 180° :** $\theta \rightarrow 180.44^\circ$ ($\mathcal{L}_{\text{tot}} = 6.70 \times 10^{10}$ – penalità per violazione vincoli)
- **Start 270° :** $\theta \rightarrow 309.53^\circ$ ($\mathcal{L}_{\text{tot}} = 4.73 \times 10^7$ – penalità per violazione vincoli)

Confronto Discreto vs. Continuo Il minimo globale ricavato dal Multi-Start converge all'angolo continuo $\theta^* = 359.79^\circ$ (equivalente a -0.21°), con una *loss* clinica totale pari a 10.9304. Il metodo differenziabile dimostra che l'ottimo discreto individuato a 0° era già estremamente prossimo al minimo assoluto continuo, confermando la validità della risoluzione della griglia a 5° e raffinando la posizione chirurgica con una precisione dell'ordine del centesimo di grado.

Task 3a: Ottimizzazione Probabilistica e Valutazione di Robustezza

Per valutare la sensibilità della configurazione ottima rispetto alle incertezze epistemiche del modello surrogato, sono state eseguite due analisi stocastiche di propagazione dell'errore.

Incerteza sull'Angolo Ottimo via Differentiable MC Dropout

Integrando il campionamento Monte Carlo Dropout ($N = 100$) all'interno del ciclo di ottimizzazione differenziabile, si è determinata la distribuzione di probabilità empirica dell'angolo ottimale $p(\theta^*)$, illustrata nella Figura 5.1.

I risultati dell'ottimizzazione probabilistica continua evidenziano:

- **Angolo ottimale medio (μ_{θ^*}):** 0.76°
- **Incerteza ($\sigma_{\theta^*}^*$):** $\pm 4.21^\circ$
- **Intervallo di Confidenza Clinica (95% CI):** $[-7.48^\circ, 9.00^\circ]$




Figura 5.1: Distribuzione di probabilità dell'angolo ottimale θ^* ottenuta tramite Differentiable MC Dropout. La linea tratteggiata rossa indica il valore medio ($\bar{\theta}^* = 0.76^\circ$), mentre la regione evidenziata corrisponde all'intervallo a 1σ ($\pm 4.21^\circ$).

Tenendo conto della varianza stocastica dei pesi della rete, la posizione chirurgica ideale rimane stabilmente centrata attorno a 0° , con un margine di fluttuazione contenuto entro $\pm 4.21^\circ$.

Analisi di Robustezza Monte Carlo su 10.000 Iterazioni

Infine, per identificare l'angolo discreto che garantisce la maggior stabilità statistica a fronte di fluttuazioni nei dati e nei pesi, è stata condotta una simulazione Monte Carlo su **10.000 iterazioni stocastiche**.

La frequenza di vittoria per ciascun angolo discreto (definita come il raggiungimento del minor valore della funzione obiettivo $\mathcal{L}_{\text{obj}}$ nel pieno rispetto dei vincoli clinici) è riassunta di seguito:

- **Angolo 0° :** Ottimo nel 33.2% dei casi (3.322 iterazioni)
- **Angolo 5° :** Ottimo nel 24.3% dei casi (2.434 iterazioni)
- **Angolo 355° :** Ottimo nel 22.6% dei casi (2.255 iterazioni)
- **Angolo 10° :** Ottimo nel 9.2% dei casi (921 iterazioni)
- **Angolo 350° :** Ottimo nel 6.2% dei casi (623 iterazioni)

L'angolo $\theta = 0^\circ$ si conferma la singola posizione più frequente con una confidenza del 33.2%. Considerando l'intero settore simmetrico compreso tra -5° e $+5^\circ$ (ovvero l'insieme degli angoli 355° , 0° e 5°), la confidenza cumulativa raggiunge l'**80.1%** (8011 iterazioni su 10000).

Questo risultato dimostra che il posizionamento della placca ad angolo nullo non è soltanto l'ottimo nominale deterministico, ma costituisce la scelta chirurgica più robusta e sicura a fronte dell'incertezza stocastica del modello.

Risultati del modello MLP con Skip connection e splitting deterministico

L'utilizzo del MLP con Skip Connection fornisce risultati robusti e in pieno accordo tra i due approcci descritti in precedenza.

Dall'analisi discreta emerge che solo 8 angoli compresi nel range $[335^\circ, 10^\circ]$ sono compatibili con i vincoli. Tra questi, la ricerca identifica la configurazione con $\theta = 0^\circ$ come la migliore con una loss clinica di 11.115.

Dall'approccio differenziabile possiamo ottenere un raffinamento del risultato discreto. Infatti, la discesa del gradiente raffina la soluzione nell'intorno della posizione angolare $\theta = 0^\circ$ ottenendo che la miglior configurazione è a $\theta = 359.52^\circ$ con una loss di 11.106 (migliore di quella ottenuta in precedenza).

Dai risultati raccolti nella seguente tabella emerge che in entrambi i casi la ricerca produce soluzioni che soddisfano pienamente i vincoli clinici.

Metrica	Esplorazione discreta	Ottimizzazione Differenziabile
$\theta_{\text{opt}} [^\circ]$	0°	359.52°
$\mathcal{L}_{\text{tot}}$	11.115	11.106
T_{tratt} [giorni]	6.38	6.38
$\bar{D}_{\text{cris}}$ [Gy]	0.56	0.56
$\bar{D}_{\text{retina}}$ [Gy]	27.95	27.99
$\bar{D}_{\text{cornea}}$ [Gy]	2.34	2.33
$\bar{D}_{\text{nervo}}$ [Gy]	9.09	8.85
$\bar{D}_{\text{sclera}}$ [Gy]	48.38	48.43

Tabella 5.1: Confronto delle metriche cliniche tra l'esplorazione su griglia discreta e l'ottimizzazione continua. Nella tabella non è presente la dose media sul tumore poiché il calcolo del tempo di trattamento garantisce, per costruzione, l'erogazione della dose prescritta al bersaglio.

I risultati ottenuti dal modello per l'ultima fase del progetto confermano e rafforzano pienamente i risultati appena presentati sulla configurazione ottimale.

Dall'analisi stocastica discreta risulta che il vincitore stocastico è la configurazione a $\theta = 0^\circ$ nel 36.9% delle simulazioni. Inoltre da questa analisi statistica emerge un ulteriore dato fondamentale: il tripletto di configurazioni formate dagli angoli $\{355^\circ, 0^\circ, 5^\circ\}$ concentra l'88.5% dei risultati delle simulazioni confermando l'affidabilità del modello. Infatti, nonostante il rumore introdotto dal Monte Carlo Dropout, il modello non disperde le soluzioni ottimali in settori anatomici casuali.

Dall'analisi stocastica sull'approccio continuo si ottiene un angolo ottimale $\mu_{\theta^*} = 1.69^\circ$ in allineamento con i risultati ottenuti nella task 2. Nella Fig.5.2 viene mostrata la zona di probabilità dell'angolo ottimale. Dal calcolo della deviazione standard emerge infine un'incertezza $\sigma_{\theta^*} = \pm 3.31^\circ$ che genera un intervallo di ampiezza pari a $\sim 7^\circ$. Questo garantisce a tutti gli effetti un buon margine di sicurezza operativa.




Figura 5.2: Distribuzione di probabilità dell'angolo ottimale θ ottenuta tramite Differentiable MC Dropout. La linea tratteggiata rossa indica il valore medio ($\mu_{\theta^*} = 1.69^\circ$), mentre la regione evidenziata corrisponde all'intervallo a 1σ ($\pm 3.31^\circ$)

Risultati del modello MLP sequenziale con splitting angolare continuo

Differenze rispetto agli altri due modelli nelle Task 2 e 3

La struttura delle Task ricalca quella dei modelli a split casuale e selezionato, ma il partizionamento a blocchi angolari, che esclude dal training e dalla validation l'intero settore $|\theta| \leq 45^\circ$, cambia sia le procedure sia l'interpretazione dei risultati. Di seguito si evidenziano solo le differenze.

Ricerca su griglia con vincoli hard (Task 2A)

Nel modello a splitting continuo la differenza di risultato è netta. In-domain gli altri modelli trovano configurazioni ammissibili; nel continuous split l'insieme ammissibile è *vuoto*,

$$\Theta_{\text{hard}} = \{\theta : M_{\text{hard}}(\theta) = 1\} = \emptyset.$$

Vincoli più restrittivi. Il risultato non dipende da un singolo vincolo marginale. Su 72 configurazioni, il limite sul tempo di irradiazione e quelli sulle dosi medie a retina, nervo ottico e sclera vengono violati in *tutte* le configurazioni:

$$n_{\text{viol}}(\text{tempo}) = n_{\text{viol}}(\text{retina}) = n_{\text{viol}}(\text{nervo}) = n_{\text{viol}}(\text{sclera}) = 72.$$

Ciascuno di questi quattro vincoli, considerato singolarmente, è quindi già sufficiente a rendere vuoto Θ_{hard} . I limiti su cristallino e cornea sono violati rispettivamente in 46 e 47 configurazioni, mentre il filtro di fisicità non esclude alcun nodo ($n_{\text{viol}}(q_j < 0) = 0$): la sovrastima è sistematica ma non produce dosi negative. Poiché $\Theta_{\text{hard}} = \emptyset$, lo score S_{OAR} non viene mai applicato e non è possibile costruire alcun ranking in questa fase.

Sensibilità della decisione hard. L'insieme vuoto è conseguenza del bias sistematico nel settore escluso, che distrugge la calibrazione assoluta. Il tempo minimo predetto è $t_{\min} = 8.4$ giorni a $\theta = 10^\circ$ - non a 0° , coerentemente con l'asimmetria angolare del modello-contro un limite $L_t = 7$ giorni. La distanza dalla soglia,

$$t_{\min} - L_t = 1.4 \text{ giorni},$$

è piccola rispetto alla dispersione MC Dropout associata alla predizione del tempo, $\sigma_{\text{MC}} = 5.2$ giorni:

$$\frac{t_{\min} - L_t}{\sigma_{\text{MC}}} \simeq 0.26.$$

La decisione binaria ammissibile/non ammissibile dipende quindi da uno scarto molto più piccolo della variabilità predittiva del surrogato. Questo rapporto va inteso come sola diagnostica interna: la dispersione MC Dropout

non è un'incertezza calibrata e non fornisce una probabilità affidabile di ammissibilità. La Task 2A diventa pertanto *diagnostica*: mostra che il surrogato non regge come classificatore rigido di ammissibilità, e motiva il ranking relativo della Task 2B.

θ	t [giorni]	Vincoli violati
10°	8.35	tempo, retina, nervo, sclera
5°	8.36	tempo, retina, nervo, sclera
15°	8.38	tempo, retina, nervo, sclera
0°	8.42	tempo, retina, nervo, sclera
20°	8.46	tempo, retina, nervo, sclera

Tabella 5.2: Le cinque configurazioni con tempo di irradiazione predetto minimo. Tutte violano il limite temporale e le dosi medie a retina, nervo ottico e sclera; nessuna raggiunge l'ammissibilità.

Ranking gerarchico lessicografico (Task 2B) — assente negli altri modelli

Poiché la Task 2A non individua alcuna configurazione ammissibile ($\Theta_{\text{hard}} = \emptyset$), lo schema “filtro dei vincoli $\rightarrow$ minimizzazione dello score” non è applicabile. Si introduce quindi un **ranking relativo** su tutte le 72 configurazioni fisiche (predizioni finite e non negative).

Classificazione temporale. Le configurazioni vengono ordinate in base al rapporto temporale normalizzato

$$\rho_t(\theta) = \frac{t(\theta)}{t_{\min}}, \quad t_{\min} = 8.4 \text{ giorni } (\theta = 10^\circ),$$

che misura di quanto il tempo si discosta dal minimo globale ($\rho_t = 1 \Leftrightarrow t = t_{\min}$). Le soglie τ_A, τ_B, τ_C definiscono quattro classi, dalla più alla meno favorevole.

Classe	Intervallo di ρ_t	N. config.
A	$1 \leq \rho_t \leq \tau_A$	8
B	$\tau_A < \rho_t \leq \tau_B$	4
C	$\tau_B < \rho_t \leq \tau_C$	4
D	$\rho_t > \tau_C$	56

Tabella 5.3: Classificazione temporale delle configurazioni; le soglie coincidono con quelle dell'implementazione. Le classi A–C sono concentrate nel settore *near-tumor*.

Criteri del ranking. Le configurazioni non vengono confrontate con un unico score sommato, ma mediante criteri applicati in ordine gerarchico: ciascun criterio interviene solo quando i precedenti non distinguono. L'ordine è

$$\boxed{\text{classe temporale} \rightarrow N_{\text{viol}} \rightarrow S_{\text{eccesso}} \rightarrow R_{\text{OAR,max}} \rightarrow S_{\text{OAR}} \rightarrow \rho_t \rightarrow \theta}$$

si privilegia cioè la classe temporale migliore; a parità di classe, la configurazione con meno soglie OAR superate (N_{viol}); poi, in sequenza, l'entità complessiva degli eccessi (S_{eccesso}), la violazione singola peggiore ($R_{\text{OAR,max}}$) e lo score OAR complessivo (S_{OAR}). Rapporto temporale esatto ρ_t e angolo θ intervengono solo come criteri finali di spareggio.

Candidato prioritario. Il primo elemento del ranking è $\theta_{\text{cand}} = 0^\circ$ (classe A), con

$$t(0^\circ) = 8.4 \text{ giorni}, \quad \rho_t(0^\circ) = 1.0075,$$

cioè solo lo 0.75% sopra il minimo a 10° . La scelta di 0° anziché 10° non è contraddittoria: le due appartengono alla stessa classe e allo stesso N_{viol} , quindi decidono i criteri dosimetrici, e per $\theta = 0^\circ$ si ha $S_{\text{eccesso}} = 1.52$ e $R_{\text{OAR,max}} = 1.55$, entrambi migliori che a 10° . Le prime posizioni ($0^\circ, 355^\circ, 5^\circ, 350^\circ, 10^\circ, \dots$) si concentrano attorno all'asse tumorale, senza simmetria perfetta — coerentemente con l'asimmetria angolare appresa dal modello.

Ottimizzazione differenziabile continua (Task 2C)

La pipeline di *differentiable programming* è quella già descritta. A differenza degli altri due modelli, quello a splitting continuo adotta una funzione obiettivo normalizzata a cinque termini — tempo, penalità temporale, penalità OAR, termine dosi massime e penalità di fisicità — con pesi

$$w_t = 1, \quad \lambda_t = 1, \quad \lambda_{\text{OAR}} = 1, \quad \lambda_{\text{max}} = 0.1, \quad \lambda_{\text{phys}} = 10,$$

e un’ottimizzazione più controllata:

- multistart da 12 angoli (passo 30°), 500 step, con `clip_grad_norm=10`, early stopping (patience 60) e rimozione dei duplicati via distanza angolare circolare;
- verifica dell’ottimo di Adam contro una griglia fine a 0.1° e contro la funzione obiettivo valutata sugli output Geant4 (passo assente negli altri modelli).

Risultati. Le 12 inizializzazioni convergono senza anomalie numeriche (12/12) e individuano 2 soluzioni distinte, a conferma della non convessità di $\mathcal{J}$. L’ottimo continuo è

$$\theta^* = 4.0268^\circ, \quad \mathcal{J}(\theta^*) = 6.634474, \quad \hat{t}(\theta^*) = 8.3713 \text{ giorni.}$$

La correttezza numerica è confermata su due fronti: il gradiente in $\theta = 0^\circ$ è negativo ($d\mathcal{J}/d\theta = -0.575 \text{ rad}^{-1}$), coerente con un minimo a $\theta > 0^\circ$, e una ricerca su griglia fine a 0.1° individua lo stesso minimo a meno di 0.03° . Il confronto con le altre soluzioni è riassunto in Tab. 5.4.

Metodo	θ	$\mathcal{J}$
Ottimo continuo (Adam)	4.0268°	6.634474
Griglia fine 0.1°	4.0°	6.634480
Miglior nodo discreto 5°	5°	6.635690
Migliore su output Geant4	0°	1.817607

Tabella 5.4: Confronto tra l’ottimo continuo e i riferimenti discreti e Geant4.

Rispetto al miglior nodo discreto a 5° , il guadagno è $\Delta\mathcal{J} = 0.001216$ (lo 0.0183%): l’ottimizzazione continua è quindi solo un *raffinamento locale*. Applicando la stessa $\mathcal{J}$ agli output Geant4, il minimo cade a 0° , a 4.0268° dall’ottimo del surrogato: emerge lo scarto di calibrazione nel settore escluso, per cui $\arg \min_{\theta} \mathcal{J}_{\text{NN}} \neq \arg \min_{\theta} \mathcal{J}_{\text{Geant4}}$.

Zona probabilistica dell’ottimo via MC Dropout (Task 3 / Task 2D).

Gli altri due modelli ottengono la robustezza in due modi: (i) la moda su N iterazioni con dropout riattivato tramite `model.train()`, riportando l’angolo “vincitore” e la sua frequenza come confidenza; (ii) una zona continua ottenuta con $N = 1000$ run di gradient descent che partono tutte da $\theta = 0^\circ$, con dropout *ricampionato a ogni step*, e statistica *lineare* $\bar{\theta} \pm 1.96\sigma$ sotto ipotesi gaussiana.

Il modello a splitting continuo modifica entrambi gli aspetti critici:

- la maschera di dropout è *fissata per run* tramite `forward hook` (una realizzazione stocastica coerente durante tutta l’ottimizzazione, condivisa tra i 12 multistart), con il modello mantenuto globalmente in `eval()`;
- l’analisi usa *statistica circolare*: vettore risultante medio, media circolare, concentrazione R , scarti riportati in $[-180^\circ, 180^\circ)$ e intervallo empirico al 95% dai quantili 2.5%–97.5%, esplicitamente qualificato come dispersione empirica e non come intervallo di confidenza clinico calibrato.

La media circolare degli ottimi MC risulta coerente con l’ottimo deterministico $\theta^* = 4.0268^\circ$ della Task 2C.

Zona probabilistica dell’ottimo via MC Dropout

La procedura riutilizza la pipeline differenziabile e la funzione obiettivo $\mathcal{J}(\theta)$ della Task 2C, ma ricava la posizione ottima sotto molte realizzazioni stocastiche della rete, per stimarne la dispersione.

Risultati. Ripetendo l’ottimizzazione dell’angolo su molte versioni perturbate della rete, le diecimila soluzioni ottenute non si disperdono, ma si addensano attorno a un unico valore. La distribuzione risultante (Fig. 5.3) è a campana singola, centrata sulla media $\theta^* \simeq 4.15^\circ$, con una larghezza tipica di circa $\pm 5.39^\circ$ e code sottili: le soluzioni molto lontane dal centro sono rare.

Il punto più importante è la coincidenza tra i due risultati ottenuti per vie diverse. L’angolo trovato dall’ottimizzazione deterministica della Task 2C ($\theta^* \simeq 4.03^\circ$) cade quasi esattamente al centro di questa distribuzione: la casualità introdotta dal dropout sposta la soluzione in modo trascurabile rispetto all’ampiezza complessiva della zona. In altre parole, la posizione ottimale non è un valore fragile che dipende dal rumore del modello, ma il centro di una regione stabile e ben identificata.

Va però ricordato che questa stabilità è una proprietà interna del modello, non una garanzia clinica. La zona si colloca interamente nel settore near-tumor, la regione esclusa dall’addestramento: la distribuzione descrive quanto il surrogato è coerente con sé stesso nell’indicare un angolo, non quanto quell’angolo sia effettivamente corretto. Anche la soluzione più stabile resta quindi un candidato da confermare con una simulazione Geant4 dedicata.




Figura 5.3: Distribuzione dell’angolo ottimo su mille ottimizzazioni ripetute sotto diverse realizzazioni del dropout. Le soluzioni si concentrano attorno alla media (linea tratteggiata rossa, 4.15°); la banda evidenzia la larghezza tipica della distribuzione ($\pm 5.39^\circ$). L’ottimo deterministico della Task 2C ($\simeq 4.03^\circ$) cade al centro della regione ad alta densità.

6 Confronto, conclusioni e obiettivi futuri

Confronto delle soluzioni e Conclusioni

Il presente lavoro ha dimostrato la fattibilità e l'efficacia dell'utilizzo di modelli surrogati differenziabili basati su reti neurali per accelerare la pianificazione dei trattamenti di brachiterapia oculare per il retinoblastoma. L'approccio ha permesso di superare l'onere computazionale delle tradizionali simulazioni Monte Carlo in Geant4, abilitando l'ottimizzazione continua della posizione della placca.

Il confronto tra le tre architetture e strategie di splitting ha evidenziato comportamenti complementari:

- **Il Modello 1 (MLP Sequenziale con Splitting Random)** ha mostrato ottime capacità di interpolazione generale. Ha predetto con elevata accuratezza il tempo di trattamento (MAPE del 4.33%) e le dosi assorbite dal tumore e dagli organi a rischio (OAR).
- **Il Modello 2 (MLP con Skip Connection e Splitting Sistemico)** ha introdotto un'architettura residua ottimizzata tramite Optuna, garantendo un'eccellente stabilità nella propagazione del gradiente e una convergenza rapida. Entrambi i primi due modelli hanno identificato con successo e in modo robusto la configurazione ottimale della placca in corrispondenza dell'angolo $\theta \approx 0^\circ$.
- **Il Modello 3 (MLP Sequenziale con Split Angolare Continuo)** ha funto da stress-test per valutare le capacità di estrapolazione, escludendo l'intero settore vicino al tumore (near-tumor) dalla fase di addestramento. Pur mostrando una sovrastima sistematica delle dosi assolute che ha portato al fallimento dei rigidi vincoli booleani, questo approccio ha dimostrato che la rete riesce comunque a conservare l'informazione relativa e l'ordinamento gerarchico delle configurazioni. L'ottimizzazione differenziabile su questo modello ha infatti individuato un minimo stabile a $\theta \approx 4.03^\circ$, confermando la solidità della rete nel guidare il posizionamento anche in regime di forte estrapolazione.

In sintesi, l'integrazione tra l'esplorazione discreta e l'ottimizzazione continua differenziabile (supportata dall'analisi di robustezza stocastica tramite Monte Carlo Dropout) fornisce uno strumento potente per la pianificazione inversa. I modelli sono in grado non solo di suggerire la posizione ottimale, ma anche di definire un margine di confidenza clinica affidabile per il posizionamento chirurgico.

Obiettivi futuri

Nonostante i risultati promettenti, le discrepanze assolute riscontrate nel regime di estrapolazione (Modello 3) evidenziano un limite legato alla scarsità e alla distribuzione dei dati geometrici forniti alla rete durante il training. Attualmente, il dataset si basa su rotazioni limitate a un singolo asse, mantenendo l'azimut fisso. Per superare queste limitazioni e compiere il prossimo passo verso l'applicazione clinica del progetto IRIDE, l'obiettivo futuro principale è quello di allenare la macchina con molti più angoli, ampliando il dataset sia variando l'angolo polare θ che l'angolo azimutale ϕ . Questa espansione sistematica consentirà di esplorare l'intero spazio tridimensionale, permettendo al modello di mappare con precisione assoluta la distribuzione di dose in qualsiasi configurazione spaziale, eliminando le zone cieche e garantendo stime altamente affidabili per ogni possibile posizionamento della placca oftalmica.